

Project No.26

ระบบปัญญาประดิษฐ์ทำนายสภาพอากาศจากภาพถ่ายดาวเทียม  
(Artificial Intelligence application for weather forecasting from satellite image)

จัดทำโดย

- |                           |             |
|---------------------------|-------------|
| 1. นายธนินทร์ อิมอโนทัย   | 58070501027 |
| 2. นายเฉลิมชัย กุลประวีณ์ | 58070501088 |
| 3. นายณนนต์ นพรัตน์       | 58070501104 |

ที่ปรึกษา

ดร.อัญชลิสา แต้ตระกูล

“ข้าพเจ้ายอมรับว่าได้อ่านเนื้อหาภายในรายงานฉบับนี้แล้ว”

.....  
(ดร.อัญชลิสา แต้ตระกูล)

อาจารย์ที่ปรึกษา



**ระบบปัญญาประดิษฐ์ทำนายสภาพอากาศจากภาพถ่ายดาวเทียม**  
(Artificial Intelligence application for weather forecasting from satellite  
image)

นายธนินทร์ อิมอโนทัย  
นายเฉลิมชัย กุลประวิณ  
นายณนนต์ นพรัตน์

โครงการนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต  
ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์  
มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี  
ปีการศึกษา 2561

ระบบปัญญาประดิษฐ์ทำนายสภาพอากาศจากภาพถ่ายดาวเทียม

นายณินทร์ อิมอโนทัย  
นายเฉลิมชัย กุลประวีณ์  
นายณนนต์ นพรัตน์

โครงการนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต  
ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์  
มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี  
ปีการศึกษา 2561  
ลิขสิทธิ์ของมหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี

คณะกรรมการสอบโครงการ

.....	ที่ปรึกษา
(ดร.อัญชลิสรา แต๋ตระกูล)	
.....	กรรมการ
(รศ.ดร.พีรพล ศิริพงษ์วุฒิกร)	
.....	กรรมการ
(ดร.จาตุรนต์ หาญสมบูรณ์)	
.....	กรรมการ
(นายราชวิชช์ สโรชวิกสิต)	

Artificial Intelligence application for weather forecasting from satellite image

Mr. Tanin Imanothai

Mr. Chalermchai Kurapavee

Mr.Nanont Noparat

A Project Submitted in Partial Fulfillment of the Requirements  
for the Degree of Bachelor of Engineering  
Department of Computer Engineering, Faculty of Engineering  
King Mongkut's University of Technology Thonburi  
Academic Year 2018

Project Committee

..... Advisor  
(Dr.Unchalisa Taetragool)

..... Committee  
(Dr.Peerapon Siripongwutikorn)

..... Committee  
(Dr.Jaturon Harnsomburana, Ph.D.))

..... Committee  
(Mr.Rajchawit Sarochawikasisit, M.Eng.)

หัวข้อโครงการ	ระบบการส่งข้อมูลผ่านเครือข่ายไร้สายอย่างปลอดภัย	
หน่วยกิตของโครงการ	3 หน่วยกิต	
จัดทำโดย	นายธนิษฐ์	อัมมโนทัย
	นายเฉลิมชัย	กุลประวีณ์
	นายณนนท์	นพรัตน์
อาจารย์ที่ปรึกษา	ดร.อัญชลีสา แต๊ตระกูล	
ระดับการศึกษา	วิศวกรรมศาสตรบัณฑิต	
ภาควิชา	วิศวกรรมคอมพิวเตอร์	
ปีการศึกษา	2561	

### บทคัดย่อ

สภาพอากาศเป็นหนึ่งในสาเหตุหลักที่ทำให้เกิดความล่าช้าของเที่ยวบิน (Flight Delay) ที่ก่อให้เกิดความเสียหายต่อทั้งผู้โดยสารและต่อสายการบิน จากงานวิจัยพบว่า ทศวรรษวิสัยทัศน์อันเนื่องมาจากสภาพอากาศเป็นสิ่งที่ทำให้นักบินกังวลใจที่สุด เนื่องจากนักบินจำเป็นต้องตัดสินใจภายใต้สภาวะวิกฤต ซึ่งต้องคำนึงถึงความปลอดภัย ความกดดันทางด้านเวลา ความพึงพอใจของผู้โดยสาร รวมไปถึงปริมาณน้ำมันที่มีอยู่อย่างจำกัดในแต่ละเที่ยวบิน ยิ่งไปกว่านั้นรายงานอุบัติเหตุทางเครื่องบินชี้ให้เห็นว่า ช่วงลงจอดที่สนามบินปลายทางเป็นช่วงที่เกิดอุบัติเหตุสูงสุด ดังนั้นเมื่อทศวรรษวิสัยทัศน์ในการลงจอดต่ำ นักบินส่วนใหญ่จึงจำเป็นต้องบินอ้อมจุดที่มีสภาวะอากาศไม่ดี หรือบินวนอยู่ด้านบนเพื่อรอให้ทศวรรษวิสัยทัศน์ในการลงจอดดีขึ้น อย่างไรก็ตามในบางกรณีนักบินอาจจำเป็นต้องนำเครื่องบินลงจอดที่สนามบินสำรองเพื่อเติมน้ำมัน เนื่องจากปริมาณน้ำมันที่มีอยู่ไม่เพียงพอ ซึ่งเป็นเหตุให้เกิดความล่าช้าและเพิ่มค่าใช้จ่ายให้กับสายการบิน ไม่ว่าจะเป็นในรูปแบบของค่าเสียโอกาส ค่าน้ำมันส่วนเกิน หรือว่าค่าเสียหายหากมีความสูญเสียเกิดขึ้น ซึ่งผลเสียเหล่านี้เกิดจากการทำนายทางสภาพอากาศที่ไม่แม่นยำเพียงพอต่อการวางแผนเที่ยวบิน [3] [10]

จากการสอบถามนักบินในประเทศไทยเบื้องต้น พบว่า เหตุการณ์ข้างต้นเกิดขึ้นอยู่บ่อยครั้งถึงแม้ว่านักบินจะต้องศึกษารายงานสภาพอากาศ การพยากรณ์อากาศ และข่าวอากาศก่อนขึ้นบิน แต่ข้อมูลเหล่านั้นมักนำเสนอในช่วงเวลากว้าง ๆ และยังไม่มีคำแนะนำเพียงพอสำหรับการพยากรณ์อากาศระยะใกล้ เช่น สำหรับเที่ยวบินภายในประเทศ หรือเที่ยวบินระยะสั้นระหว่างประเทศไทยกับประเทศเพื่อนบ้าน นอกจากนั้นประเทศไทยยังอยู่ในเขตภูมิอากาศร้อนชื้น (Tropical Climates) ซึ่งสภาพ

อากาศมีการเปลี่ยนแปลงได้ง่าย นักบินบางท่านจึงจำเป็นต้องอาศัยการศึกษาข้อมูลจากภาพถ่ายดาวเทียมเพิ่มเติมในการวางแผนการบิน รวมไปถึงการคาดการณ์ปริมาณน้ำมันที่ต้องใช้ในแต่ละเที่ยวบิน

ด้วยเหตุนี้เอง คณะผู้จัดทำจึงมีความตั้งใจที่จะนำเทคโนโลยีทางด้านปัญญาประดิษฐ์ (Artificial Intelligence) ซึ่งมีความก้าวหน้ามากในยุคปัจจุบัน มาประยุกต์ใช้กับภาพถ่ายจากดาวเทียมฮิมาวาริของประเทศญี่ปุ่นที่เปิดให้ใช้ได้โดยไม่มีค่าใช้จ่าย โดยใช้เทคนิคการสร้างโมเดลการเรียนรู้เชิงลึก (Deep Learning) เพื่อทำนายการเคลื่อนที่ของเมฆระยะสั้นที่ย่านอินฟราเรดที่เกี่ยวข้องกับเมฆที่อยู่สูง(เมฆที่อยู่สูงจะมีอุณหภูมิต่ำ และมีโอกาสเกิดเป็นเมฆฝนได้สูง) เพื่อสร้างผลทำนายพื้นที่ที่อาจจะมีโอกาสเกิดฝนตกหนัก ในช่วงเวลาไม่เกิน 3 ชั่วโมง ในบริเวณสนามบินที่ผู้ใช้งานกำหนด และนำเสนอผลการทำนายผ่านทางเว็บไซต์แอปพลิเคชันและโมบายแอปพลิเคชัน เพื่อเป็นเครื่องมือช่วยประกอบการตัดสินใจของนักบินให้เกิดการวางแผนการบินได้อย่างคุ้มค่าและปลอดภัยมากที่สุด

Project Title	Artificial Intelligence application for weather forecasting from satellite image
Project Credit	3 credits
Project Participant	Mr. Tanin Imanothai Mr. Chalermchai Kurapavee Mr. Nanont Noparat
Advisor	Dr.Unchalisa Taetragool, Ph.D.
Degree of Study	Bachelor's Degree
Department	Computer Engineering
Academic Year	2018

### Abstract

Weather is one of the major causes of flight delays that damage both passengers and airlines. Research presented that low visibility due to weather is one of the most pilots' concerns as they are responsible for making a decision under the crisis condition. Moreover, the decision must consider safety, time limitation, passengers' satisfaction, and the amount of available fuel that is typically limited on each flight. In addition, the accident reports indicated that most fatal aviation accidents occurred during the landing phase. When the visibility in landing is low, pilots then need to either circle the designated landing airport until getting better visibility, land at another nearby airport, or perform an immediate blind landing in the worst case scenario when the first two options are no longer feasible. Any option will cause some monetary loss to the airline enterprise, whether in the form of opportunity cost of lost time, additional fuel cost, or compensation for any casualty that may occur during a forced emergency landing. All of these losses and financial burden are a direct result of inaccurate weather forecasting, more specifically ineffective precipitation prediction causing flight delays. [3] [10]

Based on the preliminary interviews with pilots in Thailand, the above events often occur. Although pilots must study weather reports and the weather forecast before flying, the information is often present in a wide range of time and is not accurate enough for the near-term weather conditions such as for domestic flights or short flights between Thailand and neighboring countries. Furthermore, Thailand is also in the tropical region where the weather may change spontaneously. Some experienced pilots use satellite images to plan their flight and predict the amount of oil required for each flight.

According to the mentioned issues, our team is committed to applying the most advanced artificial intelligence technology to Japan's free-of-charge satellite images to forecast short-term weather less than 3 hours at a specific airport. The predicted clouds top movement information is used to generate heavy rain potential area will be presented on our web and mobile applications. Pilots can use it as a decision supporting tool for the most cost-effective and safe flight planning. Moreover, we strongly believe that our system can be used in many more scenarios beyond the airline industries such as outdoor events and daily commute.

## กิตติกรรมประกาศ

โครงการฉบับนี้สำเร็จลงได้ด้วยดี เนื่องจากได้รับความกรุณาอย่างสูงจาก ดร.อัญชลิสา แต่ตระกูล อาจารย์ที่ปรึกษาโครงการ ที่กรุณาให้คำปรึกษาตลอดจนปรับปรุงแก้ไขข้อบกพร่องต่างๆ ด้วยความเอาใจใส่อย่างยิ่ง ผู้ทำโครงการตระหนักถึงความตั้งใจจริงและความทุ่มเทของอาจารย์และขอกราบขอบพระคุณอย่างสูงไว้ ณ ที่นี้

ขอขอบพระคุณ กัปตัน วุฒิชัย รัตนพรสมpong ที่อนุเคราะห์ให้คำแนะนำ ข้อมูล และเสนอแนวทางการทำโครงการนี้ จนทำให้โครงการนี้สำเร็จลุล่วงไปได้ด้วยดี

ขอขอบคุณภาควิชาวิศวกรรมคอมพิวเตอร์มหาวิทยาลัยพระจอมเกล้าธนบุรีที่คอยสนับสนุนโครงการโดยการให้สถานที่ และอุปกรณ์ที่จำเป็นต่อการทำโครงการ

ขอขอบคุณนางสาวเมธิตา อ่อนศรี สำหรับการออกแบบและคำแนะนำหน้าเว็บแอปพลิเคชัน

อนึ่ง ผู้จัดทำโครงการหวังว่า โครงการนี้จะมีประโยชน์อยู่ไม่น้อย จึงขอมอบส่วนดีทั้งหมดนี้ ให้แก่เหล่าคณาจารย์ที่ได้ประสิทธิประสาทจนทำให้โครงการนี้เป็นประโยชน์สำหรับผู้ที่เกี่ยวข้อง และขอมอบความกตัญญูตเวทีตาคุณ แต่บิดา มารดา และผู้มีพระคุณทุกท่าน สำหรับข้อบกพร่องต่าง ๆ ที่อาจจะเกิดขึ้นนั้น ทางผู้จัดทำยินดีที่จะน้อมรับและรับฟังคำแนะนำจากทุกท่านที่ได้เข้ามาศึกษา เพื่อเป็นประโยชน์ในการพัฒนาโครงการนี้ต่อไป

ผู้จัดทำโครงการ

14 มีนาคม 2562



## สารบัญ

	หน้า
<b>บทที่ 1 บทนำ</b>	1
1.1 คำสำคัญ	1
1.2 ที่มาของปัญหาและแนวทางแก้ปัญหา	1
1.3 วัตถุประสงค์	3
1.4 ขอบเขตของงานวิจัย	3
<b>บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง</b>	4
2.1 อุบัติเหตุเครื่องบินกับธุรกิจการบิน	4
2.2 เทคโนโลยีที่เกี่ยวข้อง	5
2.2.1 การใช้เทคโนโลยีภาพถ่ายดาวเทียม	5
2.2.2 การทำ preprocessing image	6
2.2.3 เทคโนโลยีด้านปัญญาประดิษฐ์	9
2.2.3.1 ปัญญาประสาทเทียม	9
2.2.3.2 Convolutional Neural Network	10
2.2.3.3 โครงข่ายประสาทเทียมแบบวนซ้ำ	12
2.2.3.4 เครือข่ายลองซอร์ตเทิร์มเมมโมรี่	13
2.2.4 การใช้เว็บแอปพลิเคชันเชื่อมต่อการประมวลผล	15
2.2.5 การนำภาพถ่ายดาวเทียมสองแบบมาทับซ้อนเพื่อทำนายฝนตกหนัก	15
2.3 งานวิจัยที่เกี่ยวข้อง	17
2.3.1 A Dynamic Convolutional Layer for Short Range Weather Prediction	17
2.3.2 Precipitation Nowcasting: Leveraging Deep Recurrent Convolutional Neural Networks	20
2.3.3 Deep Learning for Precipitation Nowcasting : A Benchmark and A New Model	22
2.4 เครื่องมือที่ใช้ในการพัฒนา	23

<b>บทที่ 3 วิธีการดำเนินงาน</b>	24
3.1 ข้อกำหนดการทำงาน	25
3.2 โครงสร้างของซอฟต์แวร์	25
3.3 หน้าจอผู้ใช้	26
3.4 เครือข่ายคอนโวลูชันลงฮาร์ดแวร์	27
<b>บทที่ 4 การทดลอง และการอภิปรายผลการทดลอง</b>	28
4.1 การปรับจูนโมเดล	28
4.2 ระยะเวลาในการฝึกโมเดล	29
4.3 การประเมินผล	29
4.4 การทำนายฝนตกหนัก	34
4.4.1 การวัดผล การทำนายฝนตกหนัก	
เปรียบเทียบภาพ การทำนาย จากฮิมาวารี	34
4.4.2 การวัดผล โอกาสเกิดฝนตกหนัก	
ระหว่างผลทำนาย กับภาพที่เกิดขึ้นจริง	36
<b>บทที่ 5 สรุปผลการดำเนินงาน และข้อเสนอแนะ</b>	37
<b>บรรณานุกรม</b>	39

## รายการรูปภาพประกอบ

รูปภาพ	หน้า
1. รูปภาพแสดงสถิติเที่ยวบิน ที่เกิดอุบัติเหตุ. จาก Statistical Summary of Commercial Jet Airplane Accidents, 1959-2008, Boeing	5
2. รูปภาพแสดงการแปลงภาพจาก แบนด์ ต่างๆให้อยู่ในรูปของ RGB	6
3.รูปภาพแสดงภาพที่ได้จากการเก็บข้อมูลก่อนทำ preprocessing	7
4. รูปภาพแสดงภาพที่ได้จากการเก็บข้อมูลหลังทำ preprocessing	7
5. รูปภาพแสดงภาพระหว่างการทำ preprocessing โดยการลบเส้นประสีขาว	8
6. รูปภาพแสดงภาพระหว่างการเปรียบเทียบค่า RGB แต่ละ pixel	8
7. รูปภาพแสดงเซลล์ประสาทของมนุษย์ 1 นิวรอน	9
8. รูปภาพแสดงเพอร์เซปตรอนของประสาทเทียม	9
9. รูปภาพแสดงโครงข่ายประสาทเทียมโดยทั่วไป	10
10. รูปภาพแสดงการทำConvolutional ผ่านการ filter	11
11 . รูปภาพแสดงการทำPooling	11
12. รูปภาพแสดงตัวอย่าง architecture ของ CNN	11
13. รูปภาพแสดงการทำงานของ Recurrent Neural Networks	12
14. รูปภาพแสดงสมการของ hidden state / $y_t$	12
15. รูปภาพแสดงโครงสร้างของ LSTM	13
16. รูปภาพแสดงการเปรียบเทียบระหว่าง Vanilla Long Short Term Memory กับ Convolutional Long Short Term Memory	14
17. รูปภาพแสดง Encoder Decoder Model(Sequence to Sequence)	14
18. 18 การทามาส์กิ้ง เพื่อหาตำแหน่งที่มีค่าแสงสูง	16
19การทามาส์กิ้งเพื่อหาตำแหน่งที่มีค่าแสงที่สูง	16
20 โปรดัคส์ที่เกิดจากการบิตไวส์แอนด์(BITWISE AND) (ภาพซ้าย) และนำโปรดัคส์นั้นมา p แมพลงบน $T_{6.4}$ (ภาพขวา)	16
21. รูปภาพแสดงภาพถ่ายดาวเทียม 4 รูปที่ต่อเนื่องกันโดยแต่ละรูปห่างกัน 10 นาที โดยในงานวิจัยนี้จะทำการทำนายสภาพอากาศระยะสั้นจากภาพถ่ายดาวเทียมโดยจากรูปจะเป็นภาพถ่ายดาวเทียม 4 รูปที่ต่อเนื่องกันโดยแต่ละรูปห่างกัน 10 นาที	17
22.รูปภาพแสดงภาพโครงสร้างของ Dynamic Convolutional Layer	18
23.รูปภาพแสดงภาพการทำ Forward pass ของ Dynamic Convolutional Layer	18

รูปภาพ	หน้า
24. รูปภาพแสดงภาพการทำนายของ Dynamic Convolutional Layer	19
25. รูปภาพแสดงการเปรียบเทียบระหว่าง Vanilla Long Short Term Memory(รูปซ้าย) กับ Convolutional Long Short Term Memory(รูปขวา)	20
26. รูปภาพแสดงEncoder Decoder Model(Sequence to Sequence)	20
27. รูปภาพโอกาสในการหายถูกของการพยากรณ์อากาศระยะสั้นเปรียบเทียบกับช่วงเวลาที่ทำนาย มีการใช้ 2 วิธีในการทำนาย	21
28. รูปภาพแสดงตัวอย่างการทดลองโมเดลกับ dataset MovingMnist โดยใช้ Trajectory Optimizer และ GRU ซึ่งในรูปจะแสดงให้เห็นถึงการเคลื่อนไหวของตัวอักษร	22
29. รูปภาพแสดง Use Case Diagram	24
30. รูปภาพแสดง ตัวอย่างการทำงานของส่วนโครงสร้างซอฟต์แวร์	25
31. รูปภาพแสดงภาพแสดงหน้าเว็บ	26
32. รูปภาพแสดงภาพกล่องใส่ตัวเลขใช้ในการเลือกเวลาทุกๆ 10 นาที	27
33 แสดงสีเทียบกับค่าค่าขาดที่กำหนดเอาไว้	29
34. นำภาพ โอกาสฝนตกหนัก จากทาง สำนักงานอุตุนิยมวิทยาญี่ปุ่น มาทำ Masking โดยเอา เฉพาะบริเวณที่เป็นสีม่วง โดยจะมีแค่ค่า 0 ในบริเวณที่ไม่ใช่สีม่วง และ 255 ในบริเวณที่เป็นสี ม่วง (ภาพซ้าย) และภาพก่อนทำ สำนักงานอุตุนิยมวิทยาญี่ปุ่น (ภาพขวา)	34
35. นำภาพ Masking ของ โอกาสเกิดฝนตกหนัก (ภาพซ้าย) และภาพ Masking ที่เกิดฟังก์ชัน ทำนายฝนตกหนัก (ที่ทางผู้จัดทำสร้างขึ้นมา) (ภาพขวา) มาเปรียบเทียบกันเพื่อวัดผล ประสิทธิภาพของ ฟังก์ชันทำนายฝนตกหนัก รวมถึงการปรับ พารามิเตอร์ ต่าง ๆสำหรับ masking เพื่อให้ ความแม่นยำ สูงสุด	34

## รายการตารางประกอบ

ตาราง	หน้า
1 ตารางเครื่องมือที่ใช้ในการพัฒนา	23
2 ตารางผลการวัดความสามารถของโมเดล	28
3 ตารางระยะเวลาการฝึก	29
4 ตารางContingency table	30
5 ตารางผลจาก b08 1 ชั่วโมง	31
6 ตารางผลจาก b08 2 ชั่วโมง	31
7 ตารางผลจาก b08 3 ชั่วโมง	32
8 ตารางผลจาก b13 1 ชั่วโมง	32
9 ตารางผลจาก b13 2 ชั่วโมง	33
10 ตารางผลจาก b13 3 ชั่วโมง	33
11 ตารางสถิติสำหรับการปรับพารามิเตอร์ ต่างๆใน Heavy Rain Function	35
12 ตารางวัดผลทางสถิติของโมเดล	36
ปัญหาประติษฐ์ที่ช่วงเวลากการทำงานต่างๆ	

## บทที่ 1

### บทนำ

#### 1.1 คำสำคัญ

การทำนายสภาพอากาศ (Weather Forecast), ปัญญาประดิษฐ์ (Artificial Intelligence), การเรียนรู้เชิงลึก (Deep Learning), Long Short Term Memory (LSTM), True Color Reproduction

#### 1.2 ที่มาของปัญหาและแนวทางการแก้ปัญหา

อุตสาหกรรมการบิน (Aviation Industry) เป็นอุตสาหกรรมสำคัญที่ช่วยขับเคลื่อนการเติบโตของทางเศรษฐกิจและสังคมของโลก ขนาดของการขนส่งทางอากาศได้ขยายตัวเพิ่มเป็นสองเท่าในทุก ๆ สิบห้าปีและคาดว่าจะขยายตัวได้อีกต่อเนื่องในอัตราที่รวดเร็วยิ่งขึ้น อันเนื่องมาจากความต้องการในการเดินทางไปในที่ต่าง ๆ ทั่วโลก ส่งผลให้ธุรกิจสายการบิน (Airline Business) จำเป็นต้องเพิ่มเที่ยวบินเพิ่มจุดหมายปลายทาง รวมไปถึงการเพิ่มจำนวนเครื่องบิน ยิ่งไปกว่านั้นการพัฒนาอย่างรวดเร็วทางด้านวิศวกรรม เทคโนโลยี รวมไปถึงนวัตกรรมในปัจจุบัน ยิ่งส่งผลให้ธุรกิจสายการบินเป็นธุรกิจที่มีการแข่งขันสูง ดังนั้นสายการบินจึงจำเป็นต้องปรับตัวและเปลี่ยนแปลงไปตามตลาดให้ได้อย่างรวดเร็ว โดยผลการศึกษาจากองค์การการบินพลเรือนระหว่างประเทศ (International Civil Aviation Organization - ICAO) รายงานว่า ธุรกิจสายการบินในปัจจุบันพยายามที่จะลดต้นทุน พร้อมทั้งปรับปรุงการบริการให้ดียิ่งขึ้น เพื่อรับมือกับการขยายตัวของธุรกิจของสายการบิน อย่างไรก็ตาม หนึ่งในสาเหตุหลักที่ก่อให้เกิดค่าใช้จ่ายของสายการบิน คือ ความล่าช้าของเที่ยวบิน (Flight Delay) จากการศึกษาโดยองค์การบริหารการบินของประเทศสหรัฐอเมริกา (Federal Aviation Administration) พบว่า ความล่าช้าของเที่ยวบินในปี ค.ศ. 2010 ได้สร้างความเสียหายให้กับธุรกิจการบินถึง 8 ล้านล้านดอลลาร์สหรัฐ ซึ่งปัจจัยที่ส่งผลต่อการล่าช้าของเที่ยวบินมากที่สุด คือ สภาพอากาศ นอกเหนือจากปัจจัยอื่น ๆ เช่น การซ่อมบำรุงเครื่องบินเร่งด่วน กระบวนการจัดการ หรือความหนาแน่นของการจราจรทางอากาศ [4]

ความล่าช้าของเที่ยวบินที่เกิดจากสภาพอากาศนั้น ในหลาย ๆ ครั้งเป็นผลอันเนื่องมาจากทัศนวิสัยในการลงจอดแย่เกินกว่าที่นักบินจะสามารถเอาเครื่องลงจอดได้ จากการศึกษาพบว่าอุบัติเหตุทางเครื่องบินส่วนใหญ่เกิดขึ้นในช่วงที่เครื่องบินลงจอดที่สนามบิน (Landing) อันเนื่องมาจากอุปสรรคทางด้านสภาพอากาศ ดังนั้นเพื่อความปลอดภัยในการบิน นักบินจึงจำเป็นต้องตัดสินใจเลือกที่จะขับเครื่องบินอ้อมหลบพายุ หรือขั้ววนรอบ ๆ เพื่อรอให้สภาพอากาศดีขึ้นและพร้อมต่อการลงจอด ซึ่งส่งผลให้เส้นทางบินยาวขึ้น การเดินทางนานขึ้น ต้องใช้น้ำมันมากขึ้น โดยนักบินอาจจะจำเป็นต้องเลือกที่จะบินลงสนามบินสำรองเพื่อเติมน้ำมัน ในกรณีนี้น้ำมันไม่เพียงพอ ซึ่งวิธีการเหล่านี้ล้วนแล้วแต่เป็นการเพิ่มค่าใช้จ่ายของสายการบิน ไม่รวมถึง ค่าใช้จ่ายที่ทำอากาศยาน ค่าใช้จ่ายสำหรับผู้โดยสารและพนักงาน

บนเครื่องบิน ฯลฯ และในกรณีที่ย่ำแย่ที่สุดคือการเกิดอุบัติเหตุทางสายการบินจะต้องชดใช้ค่าเสียหายที่เกิดขึ้นเป็นจำนวนมาก ยิ่งไปกว่านั้นจากการสำรวจนักบิน โดย Judith Orasanu จาก NASA Ames Research Center พบว่า สิ่งที่นักบินกังวลใจมากที่สุด คือ ความปลอดภัยอันเนื่องมาจากสภาพอากาศที่นักบินจำเป็นต้องตัดสินใจทั้งในเรื่องของวิธีแก้ไข ความปลอดภัย และเรื่องอื่น ๆ เช่น ความพึงพอใจของผู้โดยสาร เวลาและน้ำมันที่อยู่อย่างจำกัด ส่งผลให้เกิดความยากลำบากในการตัดสินใจ [11]

จากปัญหาทั้งหมดที่กล่าวมาในข้างต้นส่วนใหญ่เกิดจากการที่พยากรณ์อากาศในระยะสั้นนั้นไม่แม่นยำเพียงพอให้นักบินสามารถวางแผนการบินได้อย่างคุ้มค่า และปลอดภัยมากที่สุดได้ นอกจากนี้ประเทศไทยยังอยู่ในเขตภูมิอากาศร้อนชื้น (Tropical Climates) มีฝนตกในประเทศไทยเฉลี่ย 1,572.5 มิลลิเมตรรวมตลอดปี และมีอากาศเปลี่ยนแปลงบ่อย ดังนั้นคณะผู้จัดทำโครงการจึงต้องการศึกษาและพัฒนาแอปพลิเคชันสำหรับการพยากรณ์อากาศระยะสั้น โดยอาศัยข้อมูลภาพถ่ายทางอากาศจากดาวเทียม ในการฝึกปัญญาประดิษฐ์ (Artificial Intelligence) ให้สามารถพยากรณ์อากาศระยะสั้น โดยมีความแม่นยำเพียงพอต่อการวางแผนการบินของนักบิน เพื่อให้เที่ยวบินนั้นปลอดภัยและใช้ทรัพยากรให้คุ้มค่ามากที่สุด [8-9]

### 1.3 วัตถุประสงค์

1. เพื่อศึกษาการพยากรณ์อากาศระยะสั้น โดยอาศัยข้อมูลภาพถ่ายทางดาวเทียม
2. เพื่อสร้างระบบประมวลผลการเรียนรู้เชิงลึกสำหรับการคาดการณ์สภาพอากาศระยะสั้น (ไม่เกิน 3 ชั่วโมง) ล่วงหน้าในบริเวณที่กำหนดไว้ให้มีความถูกต้องแม่นยำ
3. เพื่อสร้างเครื่องมือช่วยเหลือผู้ใช้งานในการทำนายการเคลื่อนตัวของเมฆ
4. เพื่อนำความรู้และเทคโนโลยีด้านปัญญาประดิษฐ์ มาประยุกต์ใช้ให้เกิดประโยชน์ต่อสังคม

### 1.4 ขอบเขตของงานวิจัย

เป้าหมายของโครงการคือ การประยุกต์ใช้เทคโนโลยีภาพถ่ายทางดาวเทียมนำเอามาประยุกต์กับการประมวลผลแบบปัญญาประดิษฐ์ เพื่อพัฒนาการทำนายสภาพอากาศระยะสั้น โดยเป็นแอปพลิเคชันที่ช่วยนักบินตลอดจนผู้ที่ต้องการทราบสภาพอากาศระยะสั้นล่วงหน้าได้อย่างมีประสิทธิภาพมากขึ้น โดยมีขอบเขตของโครงการดังนี้

1. จำเป็นต้องใช้ภาพถ่ายจากดาวเทียม Himawari ในการทำนายสภาพอากาศ
2. ระบบปัญญาประดิษฐ์สามารถทำนายการเคลื่อนที่ของเมฆ และพื้นที่ที่ฝนจะตกหนักได้ไม่เกิน 3 ชั่วโมง
3. ต้องเชื่อมต่ออินเทอร์เน็ตเพื่อเข้าใช้งานเว็บแอปพลิเคชันในการดูผลการทำนายจากภาพถ่ายดาวเทียม
4. ระบบไม่สามารถอัปเดตภาพถ่ายดาวเทียมและผลการทำนายได้ทันทีเนื่องจากแหล่งข้อมูลภาพถ่ายดาวเทียมมีความล่าช้าประมาณ 10 นาทีและ ต้องใช้เวลาในการคำนวณผลการทำนายประมาณ 5 นาที ก่อนที่จะสามารถอัปเดตผลการทำนายลงในระบบได้ใช้เวลาโดยรวมที่ล่าช้าประมาณ 15 นาที



## บทที่ 2

### ทฤษฎีและงานวิจัยที่เกี่ยวข้อง


#### 2.1 อุบัติเหตุเครื่องบินกับธุรกิจการบิน

จากการศึกษาในส่วนของเอเชีย ได้ทำการบันทึกตั้งแต่ปี 2000 จนถึงปี 2016 และบันทึกผลตาม “Type of Aircraft, Flight Phase, Aircraft flight hours” และ “Captain / Total flying hours” พบว่า การเกิดอุบัติเหตุขึ้นจากหลายปัจจัยและหลายขั้นตอนการบินที่สามารถเกิดอุบัติเหตุร้ายแรงอีกทั้งสามารถสร้างความสูญเสียต่อชีวิต โดยในที่นี้จะสนใจการลงจอดเครื่องบินอันเนื่องมาจากมีผลกระทบทางสภาพอากาศต่อการลงจอดของเครื่องบินส่งผลกระทบมากที่สุด

โดยการลงจอดของเครื่องบิน หรือ “Landing and Taxi to gate” ช่วงลงจอด(Landing phase) จะมีการลงจอดที่สนามบินปลายทางความเร็วของเครื่องบินลดลงจนถึงความเร็วที่ปลอดภัยสำหรับการวิ่งบนทางขับ (Taxi safespeed) ถือว่าเป็นการสิ้นสุดช่วงลงจอด และสิ้นสุดการเดินทางหนึ่ง Flight และ โดยเลือกทำการศึกษาภูมิภาคเอเชีย ทั้งหมด พบว่า ช่วงของการบินที่เกิดอุบัติเหตุมากที่สุดนั้น คือ ช่วงลงจอด คิดเป็นร้อยละ 54.82 จากการบันทึกข้อมูล และข้อมูลศึกษาจาก สถิติของอุบัติเหตุที่เกิดจากอุตสาหกรรมการบิน(Summary of Commercial Jet Airplane Accidents) แสดงถึงร้อยละของการเกิดอุบัติเหตุซึ่งพบว่า ช่วงของการบินที่เกิดอุบัติเหตุมากที่สุดนั้นก็ คือ ช่วงลงจอด เช่นเดียวกัน ทางด้านเหตุการณ์ที่เกิดขึ้นในประเทศไทยนั้น พบว่า พื้นที่ที่มีกัปตันประสบอุบัติเหตุ คือ ภาคใต้ อาจเป็นเพราะสภาพอากาศที่เกิดพายุฝนได้บ่อยครั้ง และได้มีการรวบรวมเหตุการณ์อุบัติเหตุครั้งสำคัญที่เกิดขึ้นในประเทศไทย ตั้งแต่ 2001 จนถึง 2016 (รายละเอียด ตามรูปแสดงสถิติช่วงของเที่ยวบินที่เกิดอุบัติเหตุ. จาก สถิติของอุบัติเหตุที่เกิดจากอุตสาหกรรมการบินสถิติของอุบัติเหตุที่เกิดจากอุตสาหกรรมการบินตั้งแต่ปี 1959 จนถึง 2008(Statistical Summary of Commercial Jet Airplane Accidents, 1959-2008, Boeing))

นอกจากนี้ยังมีปัจจัยจากความผิดพลาดที่เกิดจากมนุษย์ ซึ่งการตัดสินใจที่ผิดพลาดนั้นร้อยละ 80 เกิดจากการขาด ความตระหนักรู้ในสถานการณ์และรับรู้ข้อมูลต่างๆ(Situation Awareness) หรือที่เรียกว่า “SA” ใน ซึ่งการปฏิบัติหน้าที่ของนักบินต้องฝึกฝนให้ตัวเองนั้นมีความตระหนักรู้ในสถานการณ์และรับรู้ข้อมูล(Situation Awareness) เช่น “System Spatial Geographic Environment” มีความเข้าใจและสามารถคาดการณ์ในอนาคตได้ ถ้านักบินที่ปฏิบัติหน้าที่ที่มีความล้มเหลวจะทำให้ขาดการเฝ้าระวังในการรับรู้ข้อมูลที่สำคัญของระบบ (Critical Cue) ทำให้ขาดความตื่นตัว สภาวะที่นักบินรับรู้ถึงตำแหน่งที่อยู่ ทำทางการทรงตัวของอากาศยานที่นักบินบังคับอยู่ในตำแหน่งที่สัมพันธ์เกิดสมาธิแคบลง “Visual tunneling/Cognitive Fixation” หรือการหลงสภาพการบิน (Spatial Disorientation) กับเส้นขอบฟ้า (Horizontal line) ผิดพลาดไปจากตำแหน่งที่เป็นอยู่จริง ซึ่งสิ่งเหล่านี้นำไปสู่การตัดสินใจที่

ผิดพลาดล้วนส่งผลต่อการปฏิบัติหน้าที่ โดยจากรูปที่ 1 แสดงให้เห็นว่าอุบัติเหตุส่วนใหญ่มักจะเกิดขึ้นในช่วงลงจอด



รูปที่ 1 รูปแสดงสถิติ Phase of Flight ที่เกิดอุบัติเหตุ จากสถิติของอุบัติเหตุที่เกิดจากอุตสาหกรรมการบินตั้งแต่ปี 1959 จนถึง ปี 2008 (Statistical Summary of Commercial Jet Airplane Accidents, 1959-2008, Boeing)

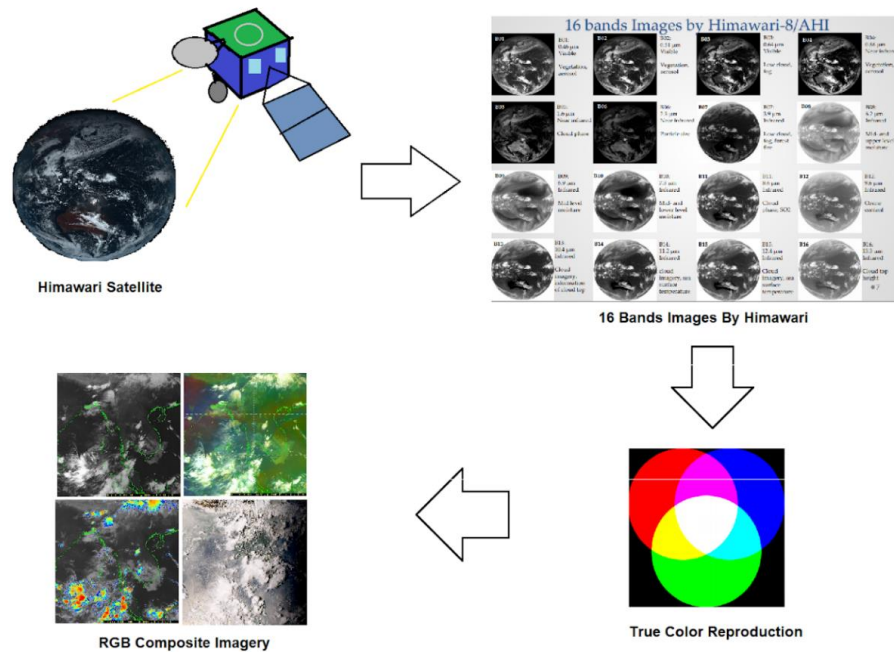
นอกจากนี้แล้วปัจจัยด้านสิ่งแวดล้อมและเครื่องจักร ที่มีสาเหตุมาจาก สภาพเครื่องยนต์ขัดข้อง น้ำมันหมดกลางทาง หาที่ลงไม่ได้ หรือ สนามบินมีเครื่องกีดขวาง หรือสภาพทางวิ่ง ทางขับไม่ดี ตลอดจนทัศนวิสัยไม่ดี เช่น ฝนตก หมอกหรือหิมะลงจัด พายุจัด ฟ้าผ่า แสงสว่างใน ปฏิบัติงานซึ่งความมืดมีผลต่อการเดินทางของเครื่องบินอีกด้วย

## 2.2 เทคโนโลยีที่เกี่ยวข้อง

### 2.2.1 การใช้เทคโนโลยีภาพถ่ายดาวเทียม

ภาพถ่ายดาวเทียมที่ใช้ จะมาจากดาวเทียมฮิมาวาริ 8 และดาวเทียม ฮิมาวาริ 9 ซึ่งภาพถ่ายจะสามารถหาได้จากเว็บไซต์ของศูนย์พยากรณ์อากาศจากดาวเทียม (Meteorological Satellite Center of JMA) ของรัฐบาลญี่ปุ่น ซึ่งภาพถ่ายจากดาวเทียมฮิมาวาริ สามารถแบ่งแยกได้ 16 ช่วง ตั้งแต่แสงช่วงที่สามารถมองเห็นได้ รังสีอินฟราเรดช่วงคลื่นสั้น จนถึงช่วงอินฟราเรดความร้อนโดยภาพจากเว็บไซต์จะถูกนำมาทำการแปลงโดย True Color Reproduction (TCR) หรือ การนำภาพจากดาวเทียมในความถี่ช่วงต่างๆ มาแปลงให้อยู่ในช่วงที่ตาของมนุษย์สามารถแยกแยะได้ โดยภาพจะมีแสงจากช่วง ย่านความถี่ที่มองเห็นได้(visible bands), ย่านความถี่ใกล้อินฟราเรด(near-infrared band), ย่านความถี่อินฟราเรด(infrared band) จะถูกนำมาแปลงเป็น รูปภาพอาร์จีบี(RGB)หรือ ช่องข้อมูลของแสงสี แดง เขียว น้ำเงิน ในไฟล์รูปภาพ โดยข้อมูลรูปภาพจะเข้ามาใหม่ทุกๆ 10 นาที โดยภาพอินฟราเรด(infrared) ที่ทางผู้จัดทำเลือกใช้ได้แก่ช่วงความยาวคลื่น  $6.2 \mu\text{m}$  ( $T_{6.2}$ ) บ่งบอกถึงรายละเอียดความชื้น


ชั้นกลางไปถึงบน(mid and upper level moisture) และ  $10.4 \mu\text{m}$  ( $T_{10.4}$ ) (ที่บอกถึงรายละเอียดเมฆที่อยู่สูง โดยเมฆที่อยู่สูงจะมีอุณหภูมิต่ำ และมีโอกาสกลั่นตัวเป็นเมฆฝนสูง) จากนั้นก็ทำการเปรียบเทียบระหว่างสองแบนด์ว่าแบนด์ไหนที่โมเดลสามารถทำนายได้แม่นยำกว่ากัน การถ่ายภาพอินฟราเรดย่านต่าง ๆ เพื่อนำมาวิเคราะห์รวมกันหลายๆย่าน แสดงให้เห็นได้ใน รูปที่ 2



รูปที่ 2 แสดงการแปลงภาพจากแบนด์ ต่างๆให้อยู่ในรูปของอาร์จีบี(RGB)


## 2.2.2 การทำ preprocessing image

ก่อนนำภาพเข้าสู่ model สำหรับการทำนายสภาพอากาศ ภาพที่ได้มาจะมีสัญญาณรบกวนเป็นเส้นบอกตำแหน่งต่างๆ ในแผนที่




### รูปที่ 3 แสดงภาพที่ได้จากการเก็บข้อมูลก่อนทำพรีโพรเซสซิง(preprocessing)

การทำพรีโพรเซสซิง(preprocessing) จะช่วยลดสัญญาณรบกวนที่มีผลต่อโมเดลการเรียนรู้เชิงลึก โดยการลบเส้นละติจูด ลองจิจูด และทำการเฉลี่ยส่วนที่เป็นเส้นทวิกับบริเวณรอบข้างแบบในรูปที่ 3 ให้เป็นดังรูปที่ 4



### รูปที่ 4 แสดงภาพที่ได้จากการเก็บข้อมูลหลังทำ preprocessing

การลบเส้นประละติจูด ลองจิจูด จะนำเส้นออกโดยการลบข้อมูลในอาร์เรย์ รูปทั้งแถวในแนวนอนและแนวตั้งแสดงให้เห็นในรูปที่ 5



### รูปที่ 5 แสดงภาพระหว่างการทำ preprocessing โดยการลบเส้นประสีขาว

การตรวจจับเส้นสีเขียวจะตรวจจับได้ในภาพที่มีรูปจากดาวเทียมที่สีเขียวจะไม่เป็นผลกับพีเจอร์ต่างๆในรูป หรือภาพที่มีลักษณะคล้ายเกรย์สเกล(gray scale) โดยในรูปที่ 6 จะแสดงความแตกต่างของแซนแนลอาร์จีบีในรูประหว่างส่วนที่เป็นสีเขียว และ ขาวดำ




**รูปที่ 6 แสดงภาพระหว่างเปรียบเทียบค่าอาร์จีบีแต่ละพิกเซล**

การตรวจจับสีเขียวจะเลือกช่องที่มีแชนแนล ที่ 2 มากกว่าแชนแนล อื่น จากนั้นจะทำการเฉลี่ยค่าในช่องนั้นกับช่องข้างๆ ที่ไม่ใช่สีเขียว โดยช่องที่ล้อมรอบด้วยสีเขียวจะเฉลี่ยกับช่องที่ผ่านการเฉลี่ยสีแล้ว

### 2.2.3 เทคโนโลยีด้านปัญญาประดิษฐ์


#### 2.2.3.1 ปัญญาประสาทเทียม(Neural Network)

เป็นเทคนิคที่เลียนแบบธรรมชาติของระบบประสาทของมนุษย์ โดยระบบประสาทของสมองมนุษย์นั้นประกอบไปด้วยเซลล์ประสาท (perceptron) จำนวนมากซึ่งเชื่อมต่อกันเป็นโครงข่ายเหมือนในรูปที่ 7



รูปที่ 7 แสดงเซลล์ประสาทของมนุษย์ 1 นิวรอน

เซลล์ประสาทรันั้นจะรับสัญญาณประสาทจากเซลล์ประสาทอื่นๆผ่านเดนไดรต์(Dendrite) แล้วทำการประมวลผลบางอย่างจากนั้นก็ส่งกระแสประสาทไปที่เซลล์ประสาทอื่นๆ ผ่านแอกซอน เทอร์มินอล(Axon Terminal) โดยที่ระบบประสาทรันั้นจะมีเซลล์ประสาทจำนวนมากประกอบเป็นโครงข่ายในหนึ่ง เพอร์เซปตรอน (Perceptron) ของเซลล์ประสาทเทียมในรูปที่ 8 และรูปที่ 9 จะประกอบไปด้วย




รูปที่ 8 แสดงเพอร์เซปตรอนของประสาทเทียม

- ฟังก์ชันโดยในที่นี้คือ  $x_1, x_2, x_3$  หรือก็คืออินพุต นั่นเอง
- น้ำหนัก(weight)เป็นพารามิเตอร์ที่เอาไว้บ่งบอกน้ำหนักของค่าฟังก์ชันต่างๆ โดยเป็นตัวบ่งบอกว่าอินพุตที่เข้ามาในเพอร์เซปตรอนนี้จะมีผลมาก หรือน้อยแค่ไหน
- $Z$  คือผลรวมของอินพุต คูณด้วยน้ำหนักของมัน
- $f(z)$  คือแอคทีเวชันฟังก์ชัน(activation function) คือการที่เอา  $Z$  มาผ่านฟังก์ชัน ใดๆก็ตามที่กำหนดไว้
- $h$  คือเอาต์พุตที่ได้จากแอคทีเวชันฟังก์ชัน

ซึ่งระบบประสาทเทียม (Neural Network) จะมีโครงสร้างแบ่งหลักๆเป็นสามชั้น ได้แก่

1. ชั้นอินพุต(Input Layer)
2. ชั้นซ่อนตัว(Hidden Layer)
3. ชั้นข้อมูลออก(Output Layer)




รูปที่ 9 แสดงโครงข่ายประสาทเทียมโดยทั่วไป

โดยเส้นทางทั่วไปของมันก็คือมี นำอินพุตเข้า ชั้นอินพุต จากนั้นก็ผ่านการประมวลผลเรื่อยๆ ตามชั้นต่างๆตั้งแต่ ชั้นอินพุต(Input Layer) → ชั้นซ่อนเร้น(Hidden Layer) → ชั้นข้อมูลออก (Output Layer) จนได้ผลลัพธ์ที่เราต้องการออกมาจาก ชั้นข้อมูลออก(Output Layer) ผ่านการ ส่งผ่านไปข้างหน้า(Feed Forward) โดยแต่ละชั้นจะประกอบไปด้วยเพอร์เซปตรอนจำนวนมากต่อกันหลายๆ ชั้น และเอาท์พุต ของเพอร์เซปตรอนหนึ่งก็จะไปเป็นอินพุต ของอีกเพอร์เซปตรอนหนึ่ง ยกเว้นเพอร์เซปตรอนในชั้นข้อมูลออก(Output Layer) และทำการเปรียบเทียบว่า เอาท์พุตที่ได้จากโครงข่ายประสาทเทียมนี้ดีหรือแย่แค่ไหน โดยทั่วไปจะมีข้อมูลจริง (Label) มายืนยันว่าเอาท์พุตนั้นต่างกับข้อมูลจริงที่เอามาเทียบแค่ไหน โดยใช้ฟังก์ชันข้อผิดพลาด(Error Function) และจะมีพีดแบคกลับไปเปลี่ยนค่าน้ำหนัก(Weight) ที่ชั้นต่างๆว่าควรเพิ่มหรือลด โดยจะมีการปรับน้ำหนัก(Weight) นั้นเริ่มจากชั้นขาออก และค่อยๆ ไล่ย้อนกลับไปชั้นขาเข้า โดยวิธีการนี้เรียกว่าการแพร่ย้อนกลับ (Back Propagation)

### 2.2.3.2 โครงข่ายประสาทเทียมแบบคอนโวลูชัน(Convolutional Neural Network)


โครงข่ายประสาทเทียมแบบคอนโวลูชัน(Convolutional Neural Network (CNN)) คือรูปแบบ โครงข่ายประสาทแบบหนึ่งของประสาทเทียม(Neural Network) โดยจากปกติที่ประสาทเทียม (Neural Network) ธรรมดาจะมีแต่ละชั้น(Layer) เป็น 1 มิติโครงข่ายประสาทเทียมแบบคอนโวลูชัน จะมีชั้นคอนโวลูชัน(convolutional layer) โดยทำการคอนโวลูชัน กับฟิลเตอร์ แทนการคูณกับน้ำหนัก ชั้นคอนโวลูชัน(convolutional layer) ดังในรูปที่ 10 แต่ละชั้นจะรับอินพุตจาก ชั้นก่อนหน้า นำมาผ่านการฟิลเตอร์โดยแต่ละฟิลเตอร์ จะทำการคอนโวลูชันกับ อินพุตและผ่านแอคทิเวชันฟังก์ชัน(activation function) ออกมาเป็นฟีเจอร์แมพ(feature maps)





รูปที่ 10 แสดงการทำConvolutional ผ่านการ filter


หลังจากผ่านชั้นคอนโวลูชัน(convolutional layer) มักจะมีชั้นพูลลิง(pooling layer) ตามรูปที่ 11 สำหรับการจับ ฟิเจอร์ส่วนที่สำคัญและตัดส่วนที่ไม่มี ฟิเจอร์ใดๆออก



รูปที่ 11 แสดงการทำPooling

จากรูปตัวอย่างจะนำฟิลเตอร์ขนาด 2x2 และสไตรด์(stride)เท่ากับ 2 มาทำการพูลลิงในรูปแบบการกรองตัวที่มากที่สุด(max pooling) โดยการเลือกกรองจุดที่มีค่ามากที่สุดมาใช้

หลังจากผ่าน ชั้นคอนโวลูชัน(convolutional layer)และชั้นพูลลิง(pooling layer) หลายๆ ชั้น ชั้นสุดท้ายของโครงข่ายประสาทเทียมแบบคอนโวลูชัน คือชั้นที่เชื่อมต่อกันอย่างสมบูรณ์(fully connected layer) ซึ่งจะเหมือนปัญหาประสาทเทียมธรรมดา ส่วนค่า loss(loss) จะนำไปอัปเดตน้ำหนักใน ชั้นที่เชื่อมต่อกันอย่างสมบูรณ์(fully connected layer)และฟิลเตอร์ในชั้นคอนโวลูชัน(convolutional layer) โครงสร้างทั้งหมดแสดงให้เห็นในรูปที่ 12




รูปที่ 12 แสดงตัวอย่าง architecture ของ CNN



### 2.2.3.3 โครงข่ายประสาทเทียมแบบวนซ้ำ(Recurrent neural network (RNN)) [5]

โครงข่ายประสาทเทียมแบบวนซ้ำเป็นประเภทหนึ่งของการทำปัญญาประดิษฐ์ประเภทโครงข่ายประสาทเทียม โดยโครงข่ายประสาทเทียมแบบวนซ้ำจะเน้นความสำคัญไปที่ข้อมูลที่มีความเกี่ยวข้องกันเป็นลำดับขั้นเวลา โดยที่ไม่เหมือนกับโครงข่ายประสาทเทียมแบบธรรมดา โดยโครงข่ายประสาทเทียมแบบวนซ้ำจะทำการใช้หน่วยความจำในการคำนวณลำดับของอินพุตทำให้กระบวนการเขียนโปรแกรมของโครงข่ายประสาทเทียมแบบวนซ้ำจะไม่สามารถแยกส่วนงานตอนคำนวณได้ แต่ต้องใส่ข้อมูลที่เป็นลำดับขั้นเข้าไปในตัวการประมวลผล



รูปที่ 13 แสดงการทำงานของ โครงข่ายประสาทเทียมแบบวนซ้ำ

จากรูปที่ 13 โครงข่ายประสาทเทียมแบบวนซ้ำ จะทำงานแบบเป็นลำดับขั้น โครงข่ายประสาท

$h_t$  จะรับ  $V$  มาจาก  $h_{t-1}$  โดย ได้รับอินพุตเป็น  $x_t$  จากในสมการที่ (1) และสมการที่ (2)

$$h_t = f_h(U_h h_{t-1} + W_h x_t + b_h) \quad \dots(1)$$

$$y_t = f_y(W_y h_t + b_y) \quad \dots(2)$$

รูปที่ 14 แสดงสมการของ สถานะซ่อนเร้น(hidden state) /  $y_t$

โดยที่

$H$  = ชั้นซ่อนเร้น(hidden layer)

$o_t$  = เอาท์พุตจากโครงข่ายประสาทเทียมแบบวนซ้ำ ที่เวลา  $t$

$x_t$  = อินพุตที่เวลา  $t$

$h_t$  = สถานะซ่อนเร้น(hidden state) ที่เวลา  $t$  โดยมีสมการดังนี้

$f_h$  คือ แอคติเวชันฟังก์ชัน ของ ชั้นซ่อนเร้น (เช่นแทนเอช(tanh) หรือรีลู(ReLU)หรือ ซิกมอยด์(sigmoid function))

$f_y$  คือ แอคติเวชันฟังก์ชันของชั้นแสดงข้อมูลออก(output layer) เช่นฟังก์ชันซอฟท์แมกซ์(SoftMax)


$W_h$  คือเมทริกซ์น้ำหนัก(weight matrix)ของชั้นซ่อนเร้น(hidden layer)

$U_h$  คือ แทรนซิชั่นเมทริกซ์ (transition matrix)

จากในสมการที่ (1) และ สมการที่ (2) ในรูปที่ 14 จะเห็นว่าการทำงานที่จะคำนวณ สถานะซ่อนเร้น (hidden state) ที่เวลา  $t$  ออกมาได้นั้น ( $h_t$ ) ก็จะต้องใช้ 2 ตัวแปรสำคัญ หรือ สถานะซ่อนเร้น(hidden state) ก่อนหน้า ( $h_{t-1}$ ) และ อินพุต ณ ตอนนั้น ( $x_t$ )

#### 2.2.3.4 เครือข่ายลองชอร์ตเทิร์มเมมโมรี(Long Short-Term Memory Networks) [6]

เครือข่ายลองชอร์ตเทิร์มเมมโมรีคือโครงข่ายประสาทเทียมแบบวนซ้ำประเภทหนึ่ง โดยเครือข่ายลองชอร์ตเทิร์มเมมโมรีจะมีโครงสร้างประกอบด้วย เมมโมรีเซลล์(memory cell), อินพุตเกต(input gate), เอาต์พุตเกต(output gate) และฟอร์เก็ตเกต(forget gate) ดังในรูปที่ 15 โดยโมเดลเครือข่ายลองชอร์ตเทิร์มเมมโมรีจะรับ ซีรีย์ของข้อมูลมาเป็นช่วงหนึ่ง จากนั้นจะทำการ เรียนรู้ โดยใช้ การแพร่ย้อนกลับผ่านเวลา(backpropagation through time)เพื่อป้องกันการเกิดปัญหาการหายไปของเกรเดียนต์(vanishing gradient problem )



รูปที่ 15 แสดงโครงสร้างของ LSTM

เซลล์ของ เครือข่ายลองชอร์ตเทิร์มเมมโมรี สามารถจดจำอินพุต ได้ระยะเวลาหนึ่งหลังจาก รับเข้ามา และมีฟังก์ชันสำหรับการคำนวณหาผลลัพธ์ โดยมีการอัปเดตข้อมูลข้างใน ปัญหาที่เจอในเครือข่ายประสาทเทียมแบบวนกลับทั่วไบนั้น คือการเกิด ปัญหาการหายไปของเกรเดียนต์ (vanishing gradient problem )

ซึ่งการทำเกรเดียนต์ คือการนำค่าลอส ที่ได้จากการทำแพร่ไปข้างหน้า(feed forward) มาอัปเดต น้ำหนัก(weight) ในปัญหาประสาทเทียมซึ่งการมีจำนวนชั้นซ่อนเร้น(hidden layer) มากเกินไปจะทำให้เกรเดียนต์นั้นลดลงจนไม่สามารถอัปเดตค่าน้ำหนัก(weight) ได้ โดยเครือข่ายลองชอร์ตเทิร์มเมมโมรี จะใช้การแพร่ย้อนกลับผ่านเวลา(backpropagation through time) ซึ่งจะนำอินพุตของแต่ละเวลามา คำนวณค่าความผิดพลาด(error)ก่อนจะนำมาอัปเดตน้ำหนัก และสิ่งที่เพิ่มมาใน เครือข่ายลองชอร์ตเทิร์มเมมโมรี อีกอย่างคือฟอร์เก็ตเกต(forget gate) ซึ่งมีไว้สำหรับเลือกข้อมูลที่จะเก็บไว้

การใช้ เครือข่ายคอนโวลูชันลองชอร์ตเทิร์มเมมโมรี (Convolutional Long Short Term Memory(ConvLSTM)) แตกต่างจากเครือข่ายลองชอร์ตเทิร์มเมมโมรี(Long Short Term Memory


(LSTM)) ทัวไปคือ จากเดิมที่ เครือข่ายลองซอร์ดเทิร์มเมมโมรีแบบทั่วไบนั้นจะเอาอินพุต, สถานะซ่อนเร้น(Hidden State )มาทำการคูณเมทริกซ์ กับน้ำหนัก(weight)

ส่วนเครือข่ายคอนโวลูชันลองซอร์ดเทิร์มเมมโมรี นั้นจะอินพุต, สถานะซ่อนเร้น(Hidden State )มาผ่านการคอนโวลูชัน โดยใช้น้ำหนัก(weight) เป็นเคอร์เนล(Kernel) แบบในรูปที่ 16 สมการที่ (3) เป็น lstm แบบปกติ และสมการที่ (4) เป็น convo lstm

$$\begin{aligned} i_t &= \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci} \circ c_{t-1} + b_i) \\ f_t &= \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf} \circ c_{t-1} + b_f) \\ o_t &= \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co} \circ c_{t-1} + b_o) \\ c_t &= f_t \circ c_{t-1} + i_t \circ \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \\ h_t &= o_t \circ \tanh(c_t) \end{aligned} \quad \dots(3)$$

$$\begin{aligned} i_t &= \sigma(W_{xi} * \mathcal{X}_t + W_{hi} * \mathcal{H}_{t-1} + W_{ci} \circ \mathcal{C}_{t-1} + b_i) \\ f_t &= \sigma(W_{xf} * \mathcal{X}_t + W_{hf} * \mathcal{H}_{t-1} + W_{cf} \circ \mathcal{C}_{t-1} + b_f) \\ o_t &= \sigma(W_{xo} * \mathcal{X}_t + W_{ho} * \mathcal{H}_{t-1} + W_{co} \circ \mathcal{C}_{t-1} + b_o) \\ \mathcal{C}_t &= f_t \circ \mathcal{C}_{t-1} + i_t \circ \tanh(W_{xc} * \mathcal{X}_t + W_{hc} * \mathcal{H}_{t-1} + b_c) \\ \mathcal{H}_t &= o_t \circ \tanh(\mathcal{C}_t) \end{aligned} \quad \dots(4)$$

รูปที่ 16 แสดงการเปรียบเทียบระหว่าง เครือข่ายลองซอร์ดเทิร์มเมมโมรีทั่วไป สมการที่(3) กับ เครือข่ายคอนโวลูชันลองซอร์ดเทิร์มเมมโมรีสมการที่(4) โดยสัญลักษณ์ (\*) คือการทำ คอนโวลูชัน และ (O) คือการทำฮาดามาร์ด(Hadamard Product)



รูปที่ 17 ดีโคดเดอร์(Encoder Decoder Model)

รูปที่ 17 แสดงถึงโมเดลเอนโค้ดเดอร์ ดีโคดเดอร์(Encoder Decoder Model(Sequence to Sequence)) โดยโหนดสีฟ้าจะแสดงถึง เซลล์คอนโวลูชันลองซอร์ดเทิร์มเมมโมรีของฝั่งเอนโค้ดเดอร์ และมีโหนดสีส้มแสดงถึง เซลล์คอนโวลูชันลองซอร์ดเทิร์มเมมโมรี ของฝั่งดีโคดเดอร์

โดยงานวิจัยนี้มีการสร้างโมเดลเป็นรูปแบบซีควเอนซ์ถึงซีควเอนซ์(Sequence to Sequence (Encoder Decoder Network)) ซึ่งเป็นโมเดลที่ไม่จำกัดขนาดของอินพุต และเอาต์พุต(Many to Many Model) โดยหลักการทำงานของโมเดลนี้คือการนำซีควเอนซ์ ของอินพุตซึ่งเป็นภาพถ่ายเรดาร์ ที่ช่วงเวลาต่างๆมาเป็นอินพุตของฝั่งเอนโค้ดเดอร์และมีเอาต์พุตจากฝั่งดีโคดเดอร์ เป็นผลทำนายของภาพถ่ายเรดาร์ ในอนาคต

#### 2.2.4 การใช้เว็บแอปพลิเคชันเชื่อมต่อการประมวลผล

ใช้ลาร์ราเวล(Laravel) เป็นเฟรมเวิร์คสำหรับ ภาษาพีเอชพีในฝั่งหลังบ้าน ใช้สำหรับดึงข้อมูลมาแสดงผล โดยข้อมูลที่จะดึงมาแสดงนั้นจะถูกส่งมาให้เว็บเซิร์ฟเวอร์หลังจากทำนายผล และใช้ เอ็มทีเอ็มแอล(HTML), ซีเอสเอส(CSS)สำหรับตกแต่งหน้าเว็บแอปพลิเคชัน

#### 2.2.5 การนำภาพถ่ายดาวเทียมสองแบบมาทับซ้อนเพื่อทำนายฝนตกหนัก [12]


การทำนายพื้นที่ที่มีฝนตกหนัก หรือ พื้นที่ที่มีอัตราฝนตกมากกว่า 20mm/h นั้น เป็นการตรวจหาเมฆที่อยู่สูง เนื่องจากเป็นเมฆที่มีอุณหภูมิต่ำและอาจก่อให้เกิดฝนตกหนัก โดยการนำภาพถ่ายดาวเทียม 2 แบนด์ที่มีความยาวคลื่นต่างกัน ( $6.2 \mu\text{m}$  ( $T_{6.2}$ ) และ  $10.4 \mu\text{m}$  ( $T_{10.4}$ ) นั้นมาเปรียบเทียบค่า Brightness ที่แต่ละ pixel เพื่อทำนายว่าจะมีฝนตกหนักที่ไหนบ้าง แต่ไม่ใช้การทำนายปริมาณน้ำฝน

- ถ้าหาก  $T_{6.2}$  มีค่าแสงต่ำกว่า  $T_{10.4}$  แปลว่าเมฆยังไม่ถึงชั้นบรรยากาศโทรโพพอส คือไม่สามารถทำให้เกิดฝนตกหนักได้
- ถ้าหาก  $T_{6.2}$  และ  $T_{10.4}$  มีค่าแสงสูงและใกล้เคียงกัน แปลว่าเมฆอยู่ที่ชั้นบรรยากาศ โทรโพพอสและมีโอกาสทำให้เกิดฝนตกหนักได้
- ถ้าหาก  $T_{6.2}$  นั้นมีค่าแสง สูงกว่า  $T_{10.4}$  แปลว่าเมฆอาจจะทะลุชั้น โทรโพพอส ไปถึงชั้น สตราโทโพสซึ่งมีโอกาสสูงมากในการเกิดฝนตกหนัก


สำหรับอัลกอริทึม นี้ โดยปกติ [11] จำเป็นต้องใช้ 3 แบนด์อินฟราเรดโดยเพิ่มเติมภาพถ่ายดาวเทียมที่มีความยาวคลื่น  $T_{12.4}$  ในการสร้างพื้นที่ที่คาดว่าจะฝนจะตกหนัก(Heavy Rain Potential Area) แต่ทางสำนักงานพยากรณ์อากาศของญี่ปุ่น(Japan Meteorological Agency) ได้ให้ข้อมูลเพียงแค่ 2 แบนด์อินฟราเรดเท่านั้น ทางผู้จัดทำจึงใช้เพียง 2 แบนด์และทำการทำนายให้ใกล้เคียงกับทาง สำนักงานพยากรณ์อากาศของญี่ปุ่นมากที่สุด

#### ขั้นตอนการการสร้างพื้นที่ที่คาดว่าจะฝนจะตกหนัก

1.การทำมาสก์กิ้ง(Masking) เพื่อหาดำแหน่งของพิกเซลที่มีค่าแสงที่สูงๆในภาพทั้ง 2 แบนด์อินฟราเรดจากในรูปที่ 18 และ 19




รูปที่ 18 การทำมาสก์กึ่ง เพื่อหาตำแหน่งที่มีค่าแสงสูง โดยพิกเซลที่มีค่าแสงสูงจะมีค่าเป็น 1 และตรงที่มีค่าต่ำกว่าจะเป็น 0 ทั้งหมด (ภาพซ้าย) และภาพ  $T_{6.2}$  ก่อนทำมาสก์กึ่ง (ภาพขวา)



รูปที่ 19 การทำมาสก์กึ่งเพื่อหาตำแหน่งที่มีค่าแสงที่สูง โดยพิกเซลที่มีค่าแสงสูงจะมีค่าเป็น 1 และตรงที่มีค่าต่ำกว่าจะเป็น 0 ทั้งหมด (ภาพซ้าย) และภาพ  $T_{10.4}$  ก่อนทำมาสก์กึ่ง (ภาพขวา)

2.การนำโปรดักส์ ที่เกิดจากการบิตไวส์แอนด์(BITWISE AND)ระหว่างมาสก์กึ่ง ของ  $T_{6.4}$  และ  $T_{10.4}$  มาแมพลองบน  $T_{6.4}$  เพื่อให้มีพื้นหลังสำหรับการแสดงผลบนหน้าแอปพลิเคชันแบบในรูปที่ 20




รูปที่ 20 โปรดักส์ที่เกิดจากการบิตไวส์แอนด์(BITWISE AND) (ภาพซ้าย) และนำโปรดักส์นั้นมา pแมพลองบน  $T_{6.4}$  (ภาพขวา)

หมายเหตุ ทางผู้จัดทำไม่ได้ทำกรณีที่  $T_{6.4}$  สูงกว่า  $T_{10.4}$  มากๆ เนื่องจากกรณีนี้ทำให้ ค่าความแม่นยำของฟังก์ชัน ต่ำลง จากการปรับจูนพารามิเตอร์ผ่านการลองผิดลองถูกโดยสำหรับการตรวจจับกรณีนี้นั้นคือการหามาส์กิ้งในช่วงต่ำๆ ของ  $T_{10.4}$  มาทำการบิตไวส์แอนด์(BITWISE AND)กับมาส์กิ้งในช่วงสูงๆของ  $T_{6.4}$  ซึ่งการกำหนดมาส์กิ้งในช่วงต่ำๆ ของ  $T_{10.4}$  นั้น หากกำหนดเรนจ์ ที่สูงเกินไปจะทำให้ความแม่นยำลดลง และหากกำหนดเรนจ์ที่ต่ำเกินไปจะไม่สามารถตรวจจับ เจอซึ่งจะให้ผลไม่แตกต่างกับการไม่ตรวจจับกรณีนี้เลย ทางผู้จัดทำจึงตัดสินใจเลือกที่จะไม่ทำในกรณีนี้

## 2.3 งานวิจัยที่เกี่ยวข้อง

### 2.3.1 A Dynamic Convolutional Layer for Short Range Weather Prediction

เลเยอร์คอนโวลูชันแบบยืดหยุ่น(Dynamic Convolutional Layer) คือเลเยอร์ชนิดใหม่ของปัญญาประสาทเทียมซึ่งประยุกต์มาจากการทำเครือข่ายปัญญาประสาทเทียมแบบคอนโวลูชันโดยในการทำ เลเยอร์คอนโวลูชันแบบยืดหยุ่นจะใช้ฟิลเตอร์ที่ต่างจากทำเครือข่ายคอนโวลูชันแบบปกติคือฟิลเตอร์ที่ใช้จะ แตกต่างกันไปในแต่ละอินพุต โดยจะมีฟังก์ชันสำหรับจับคู่ อินพุต กับ ฟิลเตอร์




รูปที่ 21 แสดงภาพถ่ายดาวเทียม 4 รูปที่ต่อเนื่องกันโดยแต่ละรูปห่างกัน 10 นาที

จากรูปที่ 21โดยในงานวิจัยนี้จะทำการทำนายสภาพอากาศระยะสั้นจากภาพถ่ายดาวเทียมโดยจากรูปจะเป็นภาพถ่ายดาวเทียม 4 รูปที่ต่อเนื่องกันโดยแต่ละรูปห่างกัน 10 นาที


#### การทำงานของเลเยอร์คอนโวลูชันแบบยืดหยุ่น

เลเยอร์คอนโวลูชันแบบยืดหยุ่นจะรับอินพุต มาจากฟีเจอร์แมพ(feature maps) จากเลเยอร์ก่อนหน้า และฟิลเตอร์โดยฟีเจอร์จะได้มาจากอินพุตจากเน็ตเวิร์คย่อย และฟิลเตอร์ จะเป็นผลมาจากการทำการคอนโวลูชันผ่านเน็ตเวิร์คกรอง(convolutional sub-network) ที่มีโครงสร้างแบบรูป 22



รูปที่ 22 แสดงภาพโครงสร้างของเลเยอร์คอนโวลูชันแบบยืดหยุ่น

จากรูป เน็ตเวิร์คบี เป็น เน็ตเวิร์คกรอง สำหรับใช้คำนวณ ฟิลเตอร์  $H1$  และ  $V1$  โดย  $SH1$  และ  $SV1$  ในรูปมาจากการนำ  $H1$  และ  $V1$  ผ่านฟังก์ชันซอฟต์แวร์แมกซ์ โดย  $DC1$  เป็น เลเยอร์คอนโวลูชันแบบยืดหยุ่น ที่นำ  $SV1$  มาใช้ในการคอนโวลูชัน และ  $DC2$  เป็น เลเยอร์คอนโวลูชันแบบยืดหยุ่นที่นำ  $SH1$  มาใช้ในการคอนโวลูชัน



รูปที่ 23 แสดงภาพการทำแพร่ไปข้างหน้าของเลเยอร์คอนโวลูชันแบบยืดหยุ่น

การทำการแพร่ไปข้างหน้า จากรูป 23 จะคำนวณฟีเจอร์แมพ ที่ให้แก่ เลเยอร์คอนโวลูชันแบบยืดหยุ่นเป็น อินพุตแรก และให้ เน็ตเวิร์คบี คำนวณฟิเตอร์ที่จะส่งต่อไปให้เลเยอร์คอนโวลูชันแบบยืดหยุ่นเป็นอินพุตที่สอง ให้  $X_{it}$  เป็นฟีเจอร์อินพุตที่  $i$  ของ แซมเปิ้ล  $t$  และ  $k_{ij}^t$  เป็น  $ij$  อินพุตคอร์เนล ของ แซมเปิ้ล  $t$

$y_j^t$  เป็นเอาต์พุตตัวที่  $j$  ของแซมเปิ้ล  $t$  จะได้การแพร่ไปข้างหน้า ที่ใช้คำนวณเอาต์พุตฟีเจอร์แมพ(output feature map) ดังสมการที่ (5)

$$y_j^n = \sum_i k_{ij}^t * x_i^t \quad \dots(5)$$



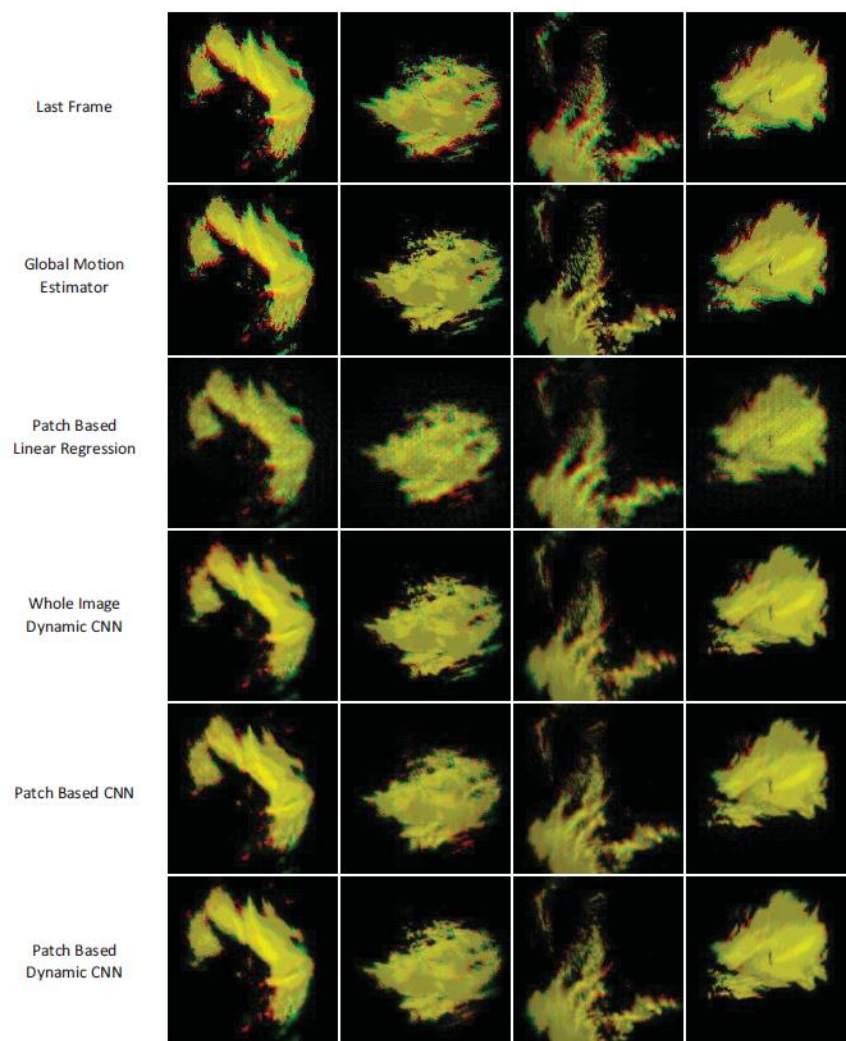
การทำการแพร่ย้อนกลับค่าเกรเดียนตจากสมการด้านล่างจะส่งผ่านเลเยอร์ในเน็ตเวิร์คเอดตามสมการที่ (6)

$$\frac{\partial l}{\partial x_i^t} = \sum_j \left( \frac{\partial l}{\partial y_j^t} \right) * (k_{ij}^t) \quad \dots(6)$$

ค่าเกรเดียนตของลอสฟังก์ชันจะคำนวณดังสมการที่ (5)

$$\frac{\partial l}{\partial k_{ij}^t} = \left( \frac{\partial l}{\partial y_j^t} \right) * (x_i^t) \quad \dots(7)$$

โดย  $k_{ij}$  จะไม่ใช่พารามิเตอร์ของเลเยอร์ แต่เป็นฟังก์ชันของอินพุต  $t$  ที่มาจากเลเยอร์ก่อนหน้า ในเน็ตเวิร์คปีค่าของเกรเดียนตจากสมการด้านบนจะส่งต่อให้เลเยอร์ที่คำนวณ  $k_{ij}^t$



รูปที่ 24 แสดงภาพการทำนายของ เลเยอร์คอนโวลูชันแบบยืดหยุ่น

ผลการทำนายเทียบสีแดงเป็นภาพที่เกิดขึ้นจริง(ground truth) สีเขียวเป็นผลทำนาย(prediction) และสีเหลืองคือส่วนที่ทับซ้อนกัน แสดงให้เห็นในรูปที่ 24



### 2.3.2 Precipitation Nowcasting: Leveraging Deep Recurrent Convolutional Neural Networks


เป็นการใช้ เครือข่ายคอนโวลูชันลงซอร์ตเทิร์มเมมโมรี (Convolutional Long Short Term Memory(ConvLSTM)) แตกต่างจากเครือข่ายลงซอร์ตเทิร์มเมมโมรี(Long Short Term Memory (LSTM)) ทั่วไปคือ จากเดิมที่ เครือข่ายลงซอร์ตเทิร์มเมมโมรีแบบทั่วไปนั้นจะเอาอินพุต, สถานะซ่อนเร้น(Hidden State) มาทำการคูณเมทริกซ์ กับน้ำหนัก(weight)

ส่วนเครือข่ายคอนโวลูชันลงซอร์ตเทิร์มเมมโมรี นั้นจะอินพุต, สถานะซ่อนเร้น(Hidden State) มาผ่านการคอนโวลูชัน โดยใช้น้ำหนัก(weight) เป็นเคอร์เนล(Kernel) จากในรูปที่ (25 )

$$\begin{aligned}
 i_t &= \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci} \circ c_{t-1} + b_i) \\
 f_t &= \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf} \circ c_{t-1} + b_f) \\
 o_t &= \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co} \circ c_{t-1} + b_o) \\
 c_t &= f_t \circ c_{t-1} + i_t \circ \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \\
 h_t &= o_t \circ \tanh(c_t)
 \end{aligned}
 \tag{3}$$

$$\begin{aligned}
 i_t &= \sigma(W_{xi} * \mathcal{X}_t + W_{hi} * \mathcal{H}_{t-1} + W_{ci} \circ \mathcal{C}_{t-1} + b_i) \\
 f_t &= \sigma(W_{xf} * \mathcal{X}_t + W_{hf} * \mathcal{H}_{t-1} + W_{cf} \circ \mathcal{C}_{t-1} + b_f) \\
 o_t &= \sigma(W_{xo} * \mathcal{X}_t + W_{ho} * \mathcal{H}_{t-1} + W_{co} \circ \mathcal{C}_{t-1} + b_o) \\
 \mathcal{C}_t &= f_t \circ \mathcal{C}_{t-1} + i_t \circ \tanh(W_{xc} * \mathcal{X}_t + W_{hc} * \mathcal{H}_{t-1} + b_c) \\
 \mathcal{H}_t &= o_t \circ \tanh(\mathcal{C}_t)
 \end{aligned}
 \tag{4}$$


รูปที่ 25 แสดงการเปรียบเทียบระหว่าง เครือข่ายลงซอร์ตเทิร์มเมมโมรีทั่วไปสมการที่ (3) กับ เครือข่ายคอนโวลูชันลงซอร์ตเทิร์มเมมโมรี สมการที่ (4) โดยสัญลักษณ์ (\*) คือการทำ คอนโวลูชัน และ (O) คือการทำฮาดามาร์ด(Hadamard Product)



รูปที่ 26 เอนโค้ดเดอร์ ดีโค้ดเดอร์(Encoder Decoder Model)

รูปที่ 26 แสดงถึงโมเดลเอนโค้ดเดอร์ ดีโคดเดอร์(Encoder Decoder Model(Sequence to Sequence)) โดยโหนดสีฟ้าจะแสดงถึง เซลล์คอนโวลูชันลงซอร์ตเทิร์มเมมโมรีของฝั่งเอนโค้ดเดอร์ และมีโหนดสีส้มแสดงถึง เซลล์คอนโวลูชันลงซอร์ตเทิร์มเมมโมรี ของฝั่งดีโคดเดอร์

โดยงานวิจัยนี้มีการสร้างโมเดลเป็นรูปแบบซีควเอนซ์ถึงซีควเอนซ์(Sequence to Sequence (Encoder Decoder Network)) ซึ่งเป็นโมเดลที่ไม่จำกัดขนาดของอินพุต และเอาต์พุต(Many to Many Model) โดยหลักการทำงานของโมเดลนี้คือการนำซีควเอนซ์ ของอินพุตซึ่งเป็นภาพถ่ายเรดาร์ ที่ช่วงเวลาต่างๆมาเป็นอินพุตของฝั่งเอนโค้ดเดอร์และมีเอาต์พุตจากฝั่งดีโคดเดอร์ เป็นผลทำนายของ ภาพถ่ายเรดาร์ในอนาคต




รูปที่ 27 โอกาสในการหายถูกของการพยากรณ์อากาศระยะสั้นเปรียบเทียบกับช่วงเวลาที่ทำนาย มีการใช้ 2 วิธีในการทำนาย โดยเส้นสีแดงนั้นคือการพยากรณ์อากาศแบบทั่วไป และเส้นประสีน้ำเงินคือการทำนายโดยใช้โมเดลซีควเอนซ์ทูซีควเอนซ์

ซึ่งผลลัพธ์ของโมเดลนี้ในรูปที่ 27 ก็ยังไม่เป็นที่น่าพึงพอใจกับการพยากรณ์อากาศระยะสั้นในช่วงเวลาที่ 3 ชั่วโมง แต่ก็ให้ผลลัพธ์ที่ดีกว่าการพยากรณ์อากาศทั่วไป

### 2.3.3 Deep Learning for Precipitation Nowcasting: A Benchmark and A New Model

เป็นการใช้ความรู้ทางด้านลองชอร์ตเทิร์มเมมโมรี(Long-short Term Memory) และ เกตเท็ครีเคอร์เร็นยูนิต(Gated Recurrent Unit) เข้ามาผสมผสานกับทราเจ็คทอรีออฟติไมเซอร์(Trajectory Optimizer) ที่มองการเคลื่อนตัวของเมฆในแต่ละช่วงเวลาของภาพถ่ายดาวเทียม เป็นการเคลื่อนตัวที่สแตติกฟิลเตอร์(static filter) แบบเครือข่ายประสาทเทียมแบบคอนโวลูชันไม่มีประสิทธิภาพเพียงพอในการตรวจจับการเคลื่อนตัว ดังนั้นเลยจำเป็นต้องมีทราเจ็คทอรีออฟติไมเซอร์ในการมาควบคุมการทำงานในส่วนสถานะ(state), เวลา(time) ที่มีความเชื่อมโยงกับการทำงานของลองชอร์ตเทิร์มเมมโมรี(Long-short Term Memory) และ เกตเท็ครีเคอร์เร็นยูนิต(Gated Recurrent Unit) อีกทั้งประยุกต์การทำงานระหว่าง เครือข่ายประสาทเทียมแบบคอนโวลูชันและ เกตเท็ครีเคอร์เร็นยูนิต ใช้ความสามารถในการฟิลเตอร์ ภาพมาใช้งานกับการเลือกจำของ เกตเท็ครีเคอร์เร็นยูนิต โดยมีการประยุกต์กับการเคลื่อนตัวของตัวอักษร จากในรูปที่ 28 ก่อนที่จะทดลองใช้กับภาพถ่ายดาวเทียมขนาด  $100 \times 100$  pixel ในการพัฒนาโมเดล




รูปที่ 28 แสดงตัวอย่างการทดลองโมเดลกับ dataset MovingMnist โดยใช้ Trajectory Optimizer และ GRU ซึ่งในรูปจะแสดงให้เห็นถึงการเคลื่อนไหวของตัวอักษร

## 2.4 เครื่องมือที่ใช้ในการพัฒนา

เครื่องมือที่ใช้ในการพัฒนาแสดงให้เห็นอยู่ในตารางที่ 1

ตารางที่ 1 เครื่องมือที่ใช้ในการพัฒนา

Python 	ภาษาที่เหมือนซูโดโค้ด(pseudo code) อ่านเข้าใจง่าย และนอกจากนั้นยังมีไลบรารีสำหรับพัฒนาปัญญาประดิษฐ์ และการจัดการข้อมูล อีกเป็นจำนวนมาก โดยโครงการนี้จะใช้ภาษาไพทอน ในการสร้างโมเดล การเรียนรู้เชิงลึก และใช้ในการสร้างไฟล์สคริปต์สำหรับการดาวน์โหลดข้อมูลรูปภาพถ่ายดาวเทียม
Pytorch 	ไลบรารีในไพทอนที่ใช้สำหรับการทำการเรียนรู้เชิงลึก โดยเอาไว้ใช้จัดการกับ เทนเซอร์(ข้อมูลที่มีหลายมิติ)
Laravel framework 	เป็นเฟรมเวิร์ค ที่ใช้ภาษา พีเอชพีในการเขียนเว็บแอปพลิเคชันฝั่งเซิร์ฟเวอร์
HTML, CSS, JQUERY 	ภาษาที่ใช้ตกแต่งหน้าเว็บแอปพลิเคชัน รวมถึงจัดการฝั่งหน้าบ้าน
Microsoft Azure web service 	สำหรับการโฮสติ้งเว็บ

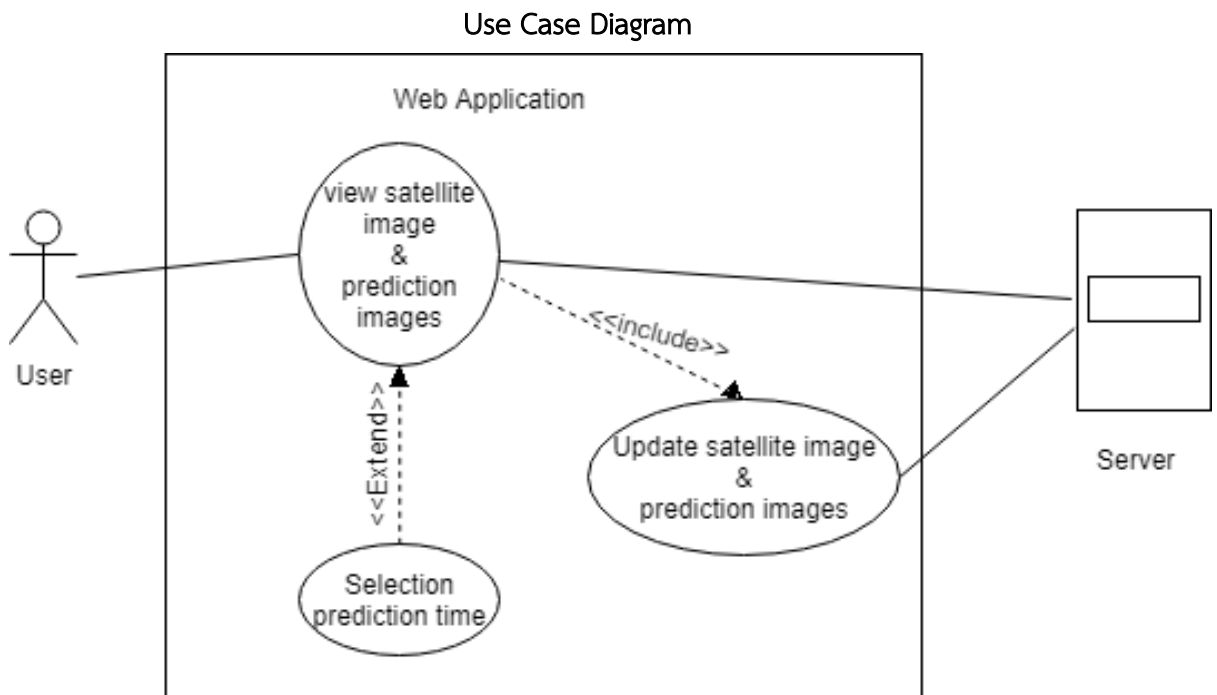
### บทที่ 3

#### การออกแบบและระเบียบวิธีวิจัย

โปรแกรมที่จะพัฒนาแบ่งออกเป็น 2 ส่วนได้แก่ส่วนของผู้ใช้งาน (terminal) จากเว็บแอปพลิเคชัน หรือ แอปพลิเคชันในมือถือ และส่วนประมวลผล (server)

ส่วนผู้ใช้งานจะรับข้อมูลภาพเป็นการทำนายการเคลื่อนตัวของเมฆจากเครื่องประมวลผล

ส่วนของการประมวลผลจะทำการรับภาพถ่ายทุก 10 นาทีจากภาพถ่ายทางดาวเทียม Himawari-8 จากนั้นนำเข้าไปในโมเดลประมวลผลภาพเพื่อทำนายการเคลื่อนตัวของเมฆ โดยมีตัวอย่าง use case diagram ในรูปที่ 29



รูปที่ 29 แสดง Use Case Diagram

### 3.1 ข้อกำหนดการทำงาน (Functional Specification)

#### ส่วนของผู้ใช้งาน

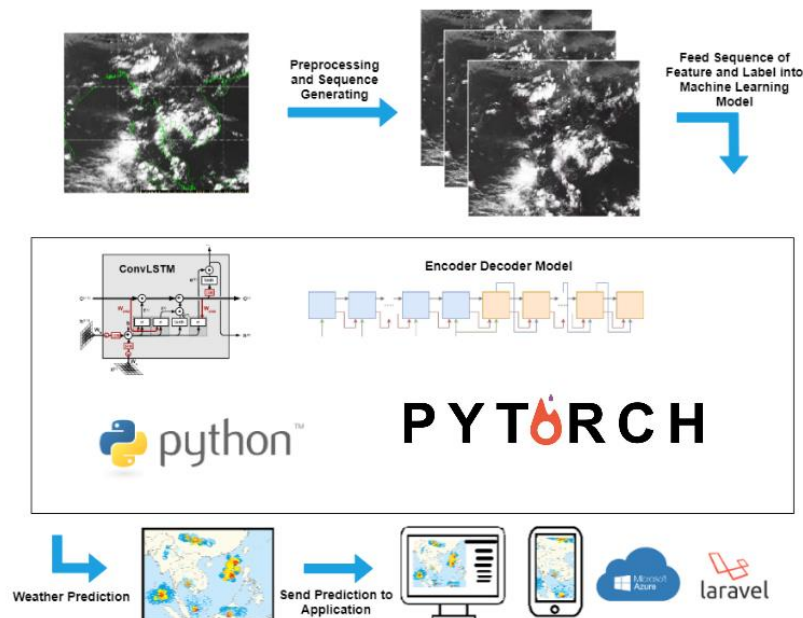
1. เว็บแอปพลิเคชันที่ใช้แสดงผลการทำนายการเคลื่อนที่ของเมฆได้
2. เว็บแอปพลิเคชันที่ใช้แสดงผลการทำนายแบบ โอกาสเกิดฝนตกหนัก ได้
3. เว็บแอปพลิเคชันสามารถดูผลการทำนายระหว่างช่วงเวลาปัจจุบันถึง 3 ชั่วโมงข้างหน้าได้ทุกๆ 10 นาที

#### ส่วนของการประมวลผล

1. เครื่องประมวลผลหลักสามารถรับความต้องการของผู้ใช้งานจากหน้าแอปพลิเคชัน
2. เครื่องประมวลผลหลักสามารถประมวลผลแล้วทำนายการเคลื่อนที่ของเมฆได้จากความต้องการของผู้ใช้งาน

### 3.2 โครงสร้างของซอฟต์แวร์ (Software Design)

หลักการทำงานของซอฟต์แวร์แสดงให้เห็นในรูปที่ 30 จะเริ่มจากการ preprocessing ภาพถ่ายดาวเทียมที่ดึงมาจาก กรมอุตุนิยมวิทยาญี่ปุ่น จากนั้นก็นำมาภาพที่ผ่านการ preprocessing มาทำการซ้อนกันกันเพื่อสร้าง ข้อมูลขาเข้า ให้กับ โมเดลลำดับข้อมูล โดยใช้ Convolution LSTM เป็น เซลเข้ารหัส (Encoder Cell) และ เซลถอดรหัส (Decoder Cell) เพื่อสร้างผลทำนายในลักษณะภาพถ่ายดาวเทียมล่วงหน้า และส่งผลทำนายมายังหน้าเว็บไซต์ที่สร้างโดยใช้ Laravel Framework

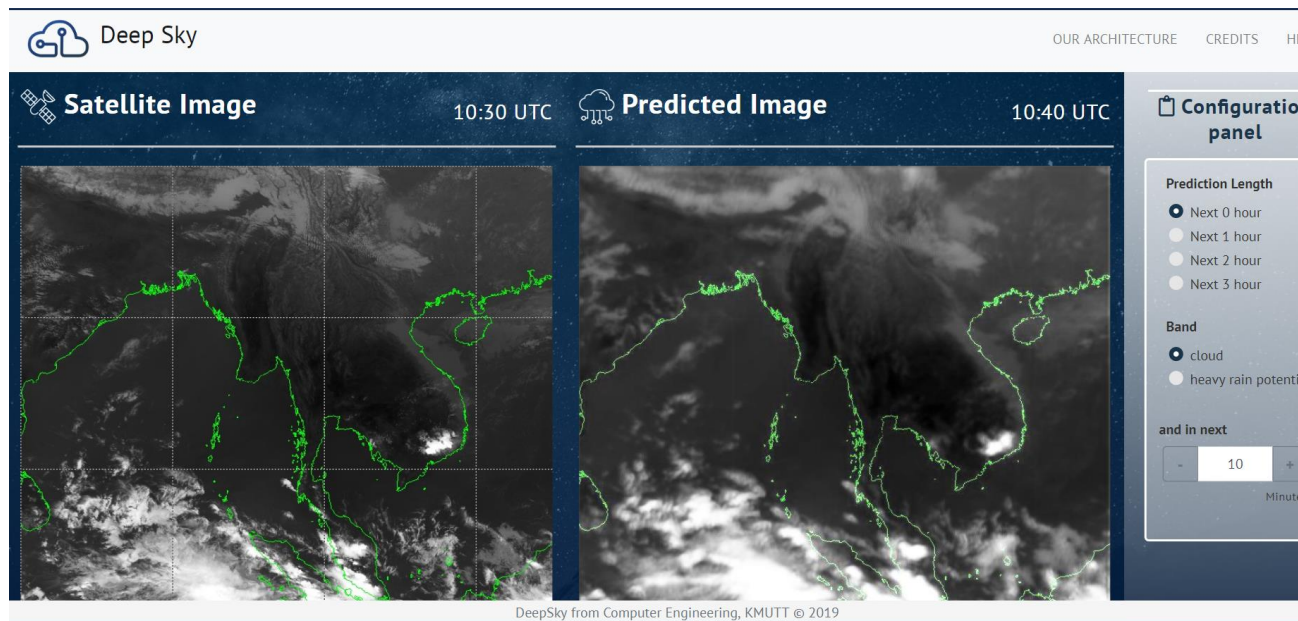


รูปที่ 30 แสดง ตัวอย่างการทำงานของส่วนโครงสร้างซอฟต์แวร์

### 3.3 หน้าจอผู้ใช้

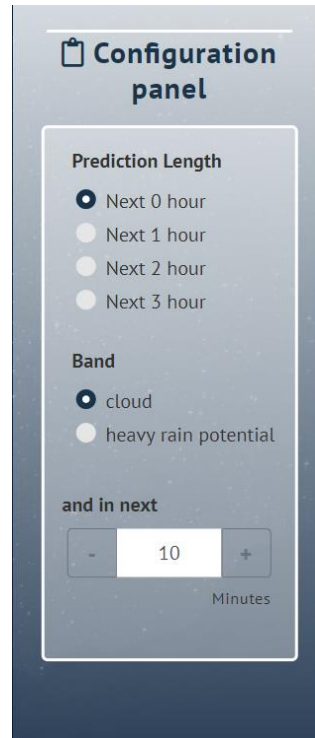
#### ส่วนของผู้ใช้

เมื่อผู้ใช้เข้าใช้งานตัวเว็บแอปพลิเคชัน ตัวเว็บไซต์จะแสดงภาพถ่ายดาวเทียม 2 รูป โดยมีภาพถ่ายดาวเทียมของจริง (ซ้าย) และ ภาพที่มาจากการทำนาย (ขวา) ในรูปที่ 31



รูปที่ 31 แสดงภาพแสดงหน้าเว็บ

ผู้ใช้สามารถเลือกระยะเวลาของผลการทำนายของรูปด้านขวาได้โดยเลือก กล้องตัวเลือก ชื่อ “การทำนาย Length” โดยมีตัวเลือกระหว่างการแสดงผลการทำนายของ 1, 2 หรือ 3 ชั่วโมงถัดไป หรือเทียบผลการทำนายก่อนหน้ากับรูปถ่ายดาวเทียมที่แสดงด้านซ้ายและสามารถเลือกเวลาทุกๆ 10 นาทีระหว่างชั่วโมงโดยการเลือกเวลาใน กล้องใส่ตัวเลข ด้านล่าง ตามรูปที่ 32



รูปที่32แสดงภาพ กล้องใส่ตัวเลข ใช้ในการเลือกเวลาทุกๆ 10 นาทีระหว่างชั่วโมงได้ หรือจะเลือกเวลาเป็นชั่วโมง และตลอดจนสามารถเลือกการแสดงผลแบบ การเคลื่อนที่ของเมฆหรือ สามารถเลือกโหมด พื้นที่เกิดฝนตกหนัก ได้ในอนาคต

### 3.4 เครือข่ายคอนโวลูชันลงซอร์ตเทิร์มเมมโมรี (Convolutional Long Short Term Memory

Convolutional LSTM นั้นเป็นหนึ่งในโมเดลที่เป็นการลงทำตามผลงานที่วิจัย Precipitation Nowcasting: Leveraging Deep Recurrent Convolutional Neural Networks โดยจะเป็นรูปแบบของ Encoder Decoder (ลำดับ to ลำดับ Model) โดยใช้ ConvLSTM Cell เป็น เข้ารหัส (Encoding) และ ถอดรหัส (Decoding) เป็น โมเดลการสร้าง (Generative Model) ที่มี การทำนาย ออกมาเป็น ภาพถ่ายเรดาร์ในอนาคต โดยนำ ชุดข้อมูล ที่เป็นลำดับของรูปภาพมาเป็น ชุดข้อมูลขาเข้า และ ป้ายกำกับ(label) สำหรับ โมเดล โดยใน 1 ลำดับ ของ ข้อมูลขาเข้า นั้นจะประกอบไปด้วยภาพ Radar 10 ภาพที่ช่วงเวลาติดๆกัน และ ป้ายกำกับ (label)จะเป็นภาพ ลำดับ Radar เช่นกัน และจะต่อจากภาพสุดท้ายของ ลำดับ ที่เป็น ข้อมูลขาเข้า เพื่อใช้ในการ กำกับ ภาพโดยขนาดของ ลำดับ จะขึ้นอยู่กับจำนวนช่วงเวลา ที่ การทำนาย ออกไป ยกตัวอย่างเช่นภาพ ข้อมูลขาเข้า จะเป็นภาพที่ช่วงเวลา 0.00 น จนถึง 1.40 น (Step ละ 10 นาที) เพราะฉะนั้น ป้ายกำกับ (label) ของ ข้อมูลขาออก ก็จะเป็นภาพที่ช่วงเวลา 1.50 จนถึง 2.50 (Step ละ 10 นาที โดยจะทำนายตั้งแต่ 10 นาทีต่อไป จนถึง 1 ชั่วโมง



## บทที่ 4

### การทดลอง และการอภิปรายผลการทดลอง

#### 4.1 การปรับจูนโมเดล

กำหนดตัวแปรในการวัดค่าความवाद้าที่ 250 , รูปจากแบนด์ 13 , ลำดับของข้อมูลขาเข้า 6 ทำนายรูปต่อไปในเวลาต่อไปอีก 1 ชั่วโมงแล้ว ทำการวัดค่า ผลลัพธ์ที่ได้จากการปรับจูนโมเดลแสดงอยู่ในตารางที่ 2

ตารางที่ 2 ผลการวัดความสามารถของโมเดล

	ค่าความแม่นยำ	ดัชนีความสำเร็จ	เวลาที่ใช้ในการเทรน
Conv-LSTM 1 cell	0.978	0.44	1 ชั่วโมง 36 นาที
Conv-LSTM 2 cell	0.972	0.284	1 ชั่วโมง 50 นาที
Conv-LSTM 3 cell	0.950	0.280	2 ชั่วโมง
Conv-LSTM 4 cell	0.943	0.278	2 ชั่วโมง 11 นาที

#### ความแม่นยำ(Accuracy)

$$Accuracy = (hits + correct\ negatives)/total$$

สามารถดูภาพรวมของการทำนายว่าถูกต้องขนาดไหน มีช่วงตั้งแต่ 0 ถึง 1 ค่าที่ดีที่สุดคือ 1

#### ดัชนีความสำเร็จ (Threat score - critical success index)

$$CSI = hits/(hits + misses + false\ alarms)$$

ความสามารถในการทำนายว่ามีเมฆเมื่อเทียบกับเหตุการณ์จริง มีช่วงตั้งแต่ 0 ถึง 1 ค่าที่ดีที่สุดคือ 1

#### สรุปผลจากการปรับจูนโมเดล

ผลจากตารางแสดงว่า เมื่อเราทำการเพิ่มจำนวนของ Conv-LSTM cell ระยะเวลาที่ใช้ในการฝึกจะเพิ่มมากขึ้นไปด้วย แต่ในที่นี่ผลที่ดีที่สุดคือค่าที่ Conv-LSTM 1 cell ที่ให้ค่า ความแม่นยำ = 0.978 และค่า CSI = 0.978 ดังนั้นในตัวโมเดลจึงใช้รูปแบบ Conv-LSTM 1 cell ในการพัฒนาโมเดล

## 4.2 ระยะเวลาในการฝึกโมเดล

ในการ ฝึก model สำหรับ สถาปัตยกรรมแบบลำดับไปยังลำดับใช้จำนวนรูปภาพทั้งหมด 17000 รูป และใช้ การ์ดจอTesla K40c ที่มี GPU memory 10 GB เวอร์ชัน CUDA version 9.0 ในการ ฝึก โดยใช้เวลา ฝึก แต่ละแบนด์ แต่ละช่วงเวลา แสดงอยู่ในตารางที่ 3 ดังนี้

ตารางที่3 ระยะเวลาการฝึก

	แบนด์ 13	แบนด์ 08
ทำนายรูปถัดไปอีก 1 ชั่วโมง	1 ชั่วโมง 36 นาที	1 ชั่วโมง 40 นาที
ทำนายรูปถัดไปอีก 2 ชั่วโมง	1 ชั่วโมง 45 นาที	1 ชั่วโมง 45 นาที
ทำนายรูปถัดไปอีก 3 ชั่วโมง	1 ชั่วโมง 48 นาที	1 ชั่วโมง 51 นาที

## 4.3 การประเมินผล

การประเมินผลจะเทียบรูปที่มาจากการทำนายเปรียบเทียบกับรูปภาพจริงว่าแต่ละพิกเซลนั้นมีเมฆหรือไม่มีเมฆ โดยกำหนดค่าขาวดำมาค่าหนึ่งสำหรับการเปรียบเทียบแต่ละครั้ง และกำหนดว่าถ้าหากค่าสีในพิกเซลสูงกว่าค่าขาวดำให้นับว่ามีเมฆ แสดงตัวอย่างค่าความสว่างในรูปที่ 33

color	threshold
	50
	75
	100
	125
	150
	175
	200
	225
	250

รูปที่ 33 แสดงสีเทียบกับค่าค่าขาวดำที่กำหนดเอาไว้

จากนั้นจะนำผลจากการเทียบที่ละพิกเซลมาเทียบในตารางจะความสัมพันธ์จาก Contingency Table [15] ในตารางที่ 4

ตารางที่ 4 Contingency table

	เหตุการณ์จริงมีเมฆ	เหตุการณ์จริงไม่มีเมฆ
ทำนายว่ามีเมฆ	Hits	False alarms
ทำนายว่าไม่มีเมฆ	Misses	Correct negatives

เมื่อหาผลรวมของการเปรียบเทียบ พิกเซล ในแต่ละภาพว่ามี Hits, Miss, False alarms, Correct negatives ว่ามีเท่าไรจะสามารถนำไปใช้เทียบคะแนนได้ดังต่อไปนี้

#### ความแม่นยำ(Accuracy)

$$Accuracy = (hits + correct\ negatives)/total$$

สามารถดูภาพรวมของการทำนายว่าถูกต้องขนาดไหน มีช่วงตั้งแต่ 0 ถึง 1 ค่าที่ดีที่สุดคือ 1

#### ค่าความลำเอียง (Bias score)

$$bias = (hits + false\ alarms)/(hits + misses)$$

ความถี่ของการทำนายว่ามีเมฆ เทียบกับเหตุการณ์ที่มีเมฆ มีช่วงตั้งแต่ 0 ถึง 1 ค่าที่ดีที่สุดคือ 1

#### โอกาสตรวจเจอ (Probability of detection - hit rate)

$$POD = hits/(hits + misses)$$

สัดส่วนที่บอกว่าการทำนายว่ามีเมฆจะถูก มีช่วงตั้งแต่ 0 ถึง 1 ค่าที่ดีที่สุดคือ 1

#### สัดส่วนตรวจพลาด (False alarm ratio - FAR)

$$FAR = false\ alarms/(hits + false\ alarms)$$

สัดส่วนที่บอกว่าการทำนายว่ามีเมฆจะผิด มีช่วงตั้งแต่ 0 ถึง 1 ค่าที่ดีที่สุดคือ 0

#### โอกาสตรวจเจอพลาด (Probability of false detection - false alarm rate)

$$POFD = false\ alarms/(correct\ negatives + false\ alarms)$$

สัดส่วนที่บอกว่าการทำนายว่ามีเมฆได้ถูกทำนายว่ามีเมฆ มีช่วงตั้งแต่ 0 ถึง 1 ค่าที่ดีที่สุดคือ 0

#### สัดส่วนความสำเร็จ (Success ratio)

$$SR = hits/(hits + false\ alarms)$$

สัดส่วนที่บอกว่าการทำนายว่ามีเมฆ สามารถทำนายได้ถูกต้อง มีช่วงตั้งแต่ 0 ถึง 1 ค่าที่ดีที่สุดคือ 1

#### ดัชนีความสำเร็จ (Threat score - critical success index)

$$CSI = hits/(hits + misses + false\ alarms)$$

ความสามารถในการทำนายว่ามีเมฆเมื่อเทียบกับเหตุการณ์จริง มีช่วงตั้งแต่ 0 ถึง 1 ค่าที่ดีที่สุดคือ 1

### ตารางผลการทำนายจากโมเดล

ทำการสลับรูปแบบเดียวกัน 1000 รูปสุดท้ายที่ไม่ใช้ในการฝึก มาทำการ ประเมินผลผลดังตารางด้านบน แล้วทำการ หาค่าเฉลี่ยของค่าที่ได้ ผลลัพธ์จากการประเมินแสดงอยู่ในตารางที่ 5, 6, 7, 8, 9 และ 10

ใช้รูปจาก แบนด์ 08 เข้าโมเดลเพื่อทำนายรูปภาพแมวในอีก 1 ชั่วโมงต่อไปได้ค่าตารางดังนี้  
ตารางที่ 5 ผลจาก แบนด์ 08 1 ชั่วโมง

threshold	accuracy	bias	POD	FAR	POFD	SR	CSI
50	0.851	1.003	0.888	0.108	0.268	0.892	0.802
75	0.837	1.005	0.791	0.206	0.148	0.794	0.658
100	0.851	1.004	0.714	0.284	0.109	0.716	0.559
125	0.872	1.009	0.634	0.364	0.083	0.636	0.469
150	0.897	1.015	0.564	0.436	0.061	0.564	0.396
175	0.921	1.016	0.505	0.492	0.044	0.508	0.343
200	0.941	1.02	0.441	0.556	0.032	0.444	0.29
225	0.962	1.037	0.364	0.634	0.02	0.366	0.229
250	0.983	1.188	0.247	0.754	0.009	0.246	0.147

ใช้รูปจาก แบนด์ 08 เข้าโมเดลเพื่อทำนายรูปภาพแมวในอีก 2 ชั่วโมงต่อไปได้ค่าตารางดังนี้  
ตารางที่ 6 ผลจาก แบนด์ 2 ชั่วโมง

threshold	accuracy	bias	POD	FAR	POFD	SR	CSI
50	0.87	0.87	0.87	0.0	0.0	1.0	0.87
75	0.718	0.718	0.718	0.0	0.0	1.0	0.718
100	0.567	0.557	0.557	0.0	0.004	1.0	0.557
125	0.551	0.454	0.453	0.001	0.002	0.999	0.453
150	0.701	0.427	0.423	0.01	0.004	0.99	0.422
175	0.879	0.55	0.489	0.113	0.015	0.887	0.462
200	0.939	0.749	0.506	0.314	0.021	0.686	0.415
225	0.965	0.854	0.431	0.449	0.014	0.551	0.324
250	0.983	0.243	0.044	0.558	0.0	0.442	0.037

ใช้รูปจาก แบนด์ 08 เข้าโมเดลเพื่อทำนายรูปภาพแมวในอีก 3 ชั่วโมงต่อไปได้ค่าตารางดังนี้

ตารางที่ 7 ผลจาก แบนด์ 3 ชั่วโมง

threshold	accuracy	bias	POD	FAR	POFD	SR	CSI
50	0.871	0.871	0.871	0.0	0.0	1.0	0.871
75	0.731	0.731	0.731	0.0	0.0	1.0	0.731
100	0.591	0.582	0.582	0.0	0.005	1.0	0.582
125	0.582	0.492	0.491	0.002	0.004	0.998	0.491
150	0.729	0.489	0.48	0.019	0.008	0.981	0.475
175	0.875	0.652	0.526	0.192	0.031	0.808	0.469
200	0.925	0.897	0.48	0.441	0.035	0.559	0.352
225	0.956	0.958	0.358	0.579	0.02	0.421	0.244
250	0.984	0.235	0.048	0.747	0.001	0.253	0.038

ใช้รูปจาก แบนด์ 13 เข้าโมเดลเพื่อทำนายรูปภาพแมวในอีก 1 ชั่วโมงต่อไปได้ค่าตารางดังนี้

ตารางที่ 8 ผลจาก แบนด์ 1 ชั่วโมง

threshold	accuracy	bias	POD	FAR	POFD	SR	CSI
50	0.851	1.003	0.888	0.108	0.268	0.892	0.802
75	0.837	1.005	0.791	0.206	0.148	0.794	0.658
100	0.851	1.004	0.714	0.284	0.109	0.716	0.559
125	0.872	1.009	0.634	0.364	0.083	0.636	0.469
150	0.897	1.015	0.564	0.436	0.061	0.564	0.396
175	0.921	1.016	0.505	0.492	0.044	0.508	0.343
200	0.941	1.02	0.441	0.556	0.032	0.444	0.29
225	0.962	1.037	0.364	0.634	0.02	0.366	0.229
250	0.983	1.188	0.247	0.754	0.009	0.246	0.147

ใช้รูปจาก แบนด์ 13 เข้าโมเดลเพื่อทำนายรูปภาพเมฆในอีก 2 ชั่วโมงต่อไปได้ค่าตารางดังนี้

ตารางที่ 9 ผลจาก แบนด์ 2 ชั่วโมง

threshold	accuracy	bias	POD	FAR	POFD	SR	CSI
50	0.851	1.003	0.888	0.108	0.268	0.892	0.802
75	0.837	1.005	0.791	0.206	0.148	0.794	0.658
100	0.851	1.004	0.714	0.284	0.109	0.716	0.559
125	0.872	1.009	0.634	0.364	0.083	0.636	0.469
150	0.897	1.015	0.564	0.436	0.061	0.564	0.396
175	0.921	1.016	0.505	0.492	0.044	0.508	0.343
200	0.941	1.02	0.441	0.556	0.032	0.444	0.29
225	0.962	1.037	0.364	0.634	0.02	0.366	0.229
250	0.983	1.188	0.247	0.754	0.009	0.246	0.147

ใช้รูปจาก แบนด์ 13 เข้าโมเดลเพื่อทำนายรูปภาพเมฆในอีก 3 ชั่วโมงต่อไปได้ค่าตารางดังนี้

ตารางที่ 10 ผลจาก แบนด์ 3 ชั่วโมง


threshold	accuracy	bias	POD	FAR	POFD	SR	CSI
50	0.851	1.003	0.888	0.108	0.268	0.892	0.802
75	0.837	1.005	0.791	0.206	0.148	0.794	0.658
100	0.851	1.004	0.714	0.284	0.109	0.716	0.559
125	0.872	1.009	0.634	0.364	0.083	0.636	0.469
150	0.897	1.015	0.564	0.436	0.061	0.564	0.396
175	0.921	1.016	0.505	0.492	0.044	0.508	0.343
200	0.941	1.02	0.441	0.556	0.032	0.444	0.29
225	0.962	1.037	0.364	0.634	0.02	0.366	0.229
250	0.983	1.188	0.247	0.754	0.009	0.246	0.147

จากผลการประเมินแบบใช้ Threshold การประเมินผลการทำนายภาพถ่ายดาวเทียมจะสนใจที่ค่าความขาวดำ มากกว่า 225 ขึ้นไป ซึ่งจัดว่าเป็นเมฆหนา โดยค่าที่สนใจจะเป็นค่าดัชนีความสำเร็จ (Critical Success Index (CSI)) ซึ่งบอกความสามารถในการทำนายว่ามีเมฆเมื่อเทียบกับเหตุการณ์จริงมากกว่าการดูค่า ความแม่นยำ เนื่องจากสัดส่วนของพิกเซลที่ไม่มีเมฆจะมากกว่า จะได้ว่าการใช้ภาพจากแบนด์ 13 ( $T_{10.4}$ ) จะให้ผลที่แม่นยำและชัดเจนมากกว่า แบนด์ 08 ( $T_{6.2}$ ) และเมื่อทำนายล่วงหน้าไปไกลมากขึ้น ความแม่นยำจะลดลง

#### 4.4 การทำนายฝนตกหนัก


##### 4.4.1 การวัดผล การทำนายฝนตกหนักเปรียบเทียบกับภาพการทำนายจากฮิมาวาริ

เนื่องด้วยทาง สำนักงานอุตุนิยมวิทยาญี่ปุ่น Japan Meteorological Agency(JMA) นั้นไม่ได้ปล่อยภาพถ่ายเทียมสำหรับทุก แบนด์ (มี แบนด์อินฟาเรดเพียง 3 bands ได้แก่ B03 ( $T_{0.64}$ ), แบนด์08 ( $T_{6.2}$ ), และ แบนด์13 ( $T_{10.4}$ ) ในขณะที่ วิธีทำนายฝนตกหนัก จากทาง ฮิมาวาริ นั้นจำเป็นต้องใช้ B08 ( $T_{6.2}$ ), B13 ( $T_{10.4}$ ), และ B15 ( $T_{12.4}$ ) ซึ่งทางผู้จัดทำขาด B15 ( $T_{12.4}$ ) ทำให้ต้องใช้เพียง B08 ( $T_{6.2}$ ) และ B13 ( $T_{10.4}$ ) มาเปรียบเทียบกับกันเพื่อสร้าง ฟังก์ชันการทำนายฝนตกหนัก ให้ใกล้เคียงกับทาง สำนักงานอุตุนิยมวิทยาญี่ปุ่น มากที่สุด



รูปที่ 34 บริเวณฝนตกหนักจากกรมอุตุนิยมวิทยาญี่ปุ่น

รูปที่ 34 นำภาพ โอกาสฝนตกหนัก จากทาง สำนักงานอุตุนิยมวิทยาญี่ปุ่น มาทำ Masking โดยเอาเฉพาะบริเวณที่เป็นสีม่วง โดยจะมีแค่ค่า 0 ในบริเวณที่ไม่ใช่สีม่วง และ 255 ในบริเวณที่เป็นสีม่วง (ภาพซ้าย) และภาพก่อนทำ สำนักงานอุตุนิยมวิทยาญี่ปุ่น (ภาพขวา)



รูปที่ 35 การเทียบบริเวณฝนตกหนักที่สร้างขึ้น

รูปที่ 35 นำภาพ Masking ของ โอกาสเกิดฝนตกหนัก (ภาพซ้าย) และภาพ Masking ที่เกิดฟังก์ชันทำนายฝนตกหนัก (ที่ทางผู้จัดทำสร้างขึ้นมา) (ภาพขวา) มาเปรียบเทียบกับกันเพื่อวัดผลประสิทธิภาพของ

ฟังก์ชันทำนายฝนตกหนัก รวมถึงการปรับ พารามิเตอร์ ต่าง ๆ สำหรับ masking เพื่อให้ ความแม่นยำ สูงสุด

ตารางที่ 11 ตารางสถิติสำหรับการปรับพารามิเตอร์ต่าง ๆ ใน ฟังก์ชันทำนายฝนตกหนัก

R1	R2	ACC	POD	FAR	POFD	SR	CSI
230-255	-	0.977	0.999	0.683	0.024	0.317	0.317
230-255	0-200	0.97	0.99	0.733	0.030	0.267	0.267
250-255	-	0.994	0.937	0.351	0.006	0.649	0.622
250-255	0-200	0.956	0.937	0.998	0.320	0.022	0.022
250-255	0-100	0.993	0.937	0.365	0.005	0.634	0.609
250-255	0-50	0.994	0.937	0.351	0.005	0.649	0.622

จากตารางที่ 11 แสดงประสิทธิภาพของการทำนายฝนตกหนัก โดย R1 คือ range ค่า ความสว่างในแต่ ละพิกเซล และนำมาทำการ bitwise AND กันทั้งสอง อินฟारेดแบนด์ เพื่อหาเมฆที่ทำให้ฝนตกหนัก R2 คือ range ที่เอาไว้ ตรวจจับ  $T_{10.4}$  ที่มีค่าต่ำๆ เพื่อเปรียบเทียบเวลาที่  $T_{6.2}$  มากกว่า  $T_{10.4}$  มากๆ (โดย การนำ Masking จาก R1 ของ  $T_{6.2}$  มา bitwise AND กับ Making จาก R2 ของ  $T_{10.4}$ ) เอาไว้ใช้ ตรวจจับ เมฆที่อยู่ชั้น สตราโตสเฟียร์

ผลการประเมินแบบ โอกาสเกิดฝนตกหนัก เปรียบเทียบกับภาพ โอกาสเกิดฝนตกหนัก จาก อี มาวาริ จะพบว่าการกำหนด R2 ที่สูงไปนั้น จะทำให้เกิด โอกาสตรวจพลาด มากขึ้น และการที่กำหนด R2 ต่ำไปก็จะ ตรวจจับ ไม่เจอซึ่งไม่ต่างจากการเอาเฉพาะส่วนที่  $T_{6.2}$  มีค่าสูง และใกล้เคียงกับ  $T_{10.4}$  อย่างเดียว ทำให้ผู้จัดทำเลือกที่จะไม่ ตรวจจับ เมฆที่อยู่ในชั้น สตราโตสเฟียร์ และเอาเฉพาะส่วนที่  $T_{6.2}$  มีค่าสูง และใกล้เคียงกับ  $T_{10.4}$  ใน Range R1 ที่ให้ CSI สูงสุด โดยจะนำพารามิเตอร์ และ ฟังก์ชัน นี้มา ใช้เพื่อสร้างตัว กำกับ ให้ตัววัดผลสำหรับตรวจสอบประสิทธิภาพของโมเดล



#### 4.4.2 การวัดผล โอกาสเกิดฝนตกหนัก ระหว่างผลทำนาย กับภาพที่เกิดขึ้นจริง

หลักการคือการนำภาพทำนาย และภาพที่เกิดขึ้นจริงจาก band B08 ( $T_{6.2}$ ) และ B13 ( $T_{10.4}$ ) มาแสดง โอกาสเกิดฝนตกหนัก ผ่าน โอกาสเกิดฝนตกหนัก ฟังก์ชัน จากนั้นจึงทำการเทียบ ลำดับภาพว่า โอกาสเกิดฝนตกหนัก ที่เกิดจากการทำนาย และที่เกิดขึ้นจริงว่าเป็นไปตามผลทำนายมากน้อยเพียงใด

ตารางที่ 12 ตารางวัดผลทางสถิติของโมเดลปัญญาประดิษฐ์ที่ช่วงเวลาการทำนายต่าง ๆ

การทำนาย range	ACC	POD	FAR	POFD	SR	CSI
1	0.988	0.670	0.498	0.008	0.502	0.403
2	0.984	0.420	0.628	0.009	0.372	0.246
3	0.973	0.435	0.787	0.021	0.213	0.167

จากตารางที่ 12 ผลการประเมินแบบ โอกาสเกิดฝนตกหนัก เปรียบเทียบกับภาพ โอกาสเกิดฝนตกหนัก จาก ฮิมาวารี พบว่ายิ่งช่วงเวลาการทำนายนานออกไป ประสิทธิภาพของโมเดลจะลดลงอย่างเห็นได้ชัด นอกจากนั้นโมเดลจะมีโอกาสทำนายว่าฝนตก แล้วตกจริง ๆ ได้ต่ำ(POD ต่ำ) แต่มีความน่าเชื่อถือสูงเวลาทายว่าตรงนั้นจะไม่เกิดฝน แล้วไม่เกิดฝนจริง ๆ

## บทที่ 5

### สรุปผลการดำเนินงาน และข้อเสนอแนะ

โครงการระบบปัญญาประดิษฐ์ทำนายสภาพอากาศจากภาพถ่ายดาวเทียม เป็นการนำผลการเคลื่อนที่ของเมฆโดยใช้โมเดลการเรียนรู้เชิงลึก การดำเนินงานเริ่มต้นจากการรวบรวมความต้องการของนักบินผ่านการสัมภาษณ์โดยตรงเพื่อนำมาออกแบบโครงงาน จากนั้นคณะผู้จัดทำได้ทำการรวบรวมข้อมูลภาพถ่ายดาวเทียมจากดาวเทียมฮิมาวาริ และศึกษาการทำงานของ คอนโวลูชันลงซอร์ตเทิร์มเมมโมรี ซึ่งเป็นโมเดลการเรียนรู้เชิงลึกประเภทหนึ่ง โดยหลังจากการ preprocessing ภาพถ่ายดาวเทียมแล้ว รูปภาพเหล่านั้นจะถูกนำมาใช้เป็นข้อมูลในการทดลองสร้างและปรับจูนโมเดล ทั้งนี้คณะผู้จัดทำได้ทำการพัฒนาเว็บแอปพลิเคชันสำหรับการแสดงภาพถ่ายดาวเทียมจริงพร้อมกับผลการทำนายสภาพอากาศตั้งแต่ 10 นาทีต่อไป จนถึง 3 ชั่วโมง นอกจากนี้คณะผู้จัดทำยังได้นำผลทำนายมาประมวลผลเพิ่มเติมเพื่อสร้างพื้นที่ที่คาดว่าฝนจะตกหนัก แล้วทำการวัดผลโดยเปรียบเทียบระหว่างพื้นที่ฝนตกหนัก ที่เกิดจากการประมวลผลจากภาพทำนาย กับพื้นที่ ที่ทำนายว่าฝนตกหนัก ที่เกิดจากการประมวลผลจากภาพที่เกิดขึ้นจริง พิกเซลต่อพิกเซล ผลจากการวิจัยพบว่าประสิทธิภาพของโมเดลที่ได้มีความใกล้เคียงกับงานวิจัยอื่น ๆ ที่คณะผู้จัดทำได้ศึกษา เช่น “Deep Learning for Precipitation Nowcasting: A Benchmark and A New Model” [14] ดังนั้นคณะผู้จัดทำจึงมีความเห็นว่าโครงการนี้จะเป็นประโยชน์ต่อนักบินที่บินในสายการบินระยะสั้น โดยใช้เว็บแอปพลิเคชันในการดูสภาพอากาศล่วงหน้าเพื่อใช้ในการวางแผนเที่ยวบินที่ปลอดภัย และคุ้มค่ามากที่สุด

จากโครงการนี้ คณะผู้จัดทำได้เรียนรู้การออกแบบและการสร้างระบบประมวลผลการเรียนรู้เชิงลึกสำหรับการคาดการณ์สภาพอากาศระยะสั้นโดยมีการประยุกต์ ใช้กับอัลกอริทึม คอนโวลูชันลงซอร์ตเทิร์มเมมโมรี และเทคนิคการพยากรณ์อากาศจากภาพอินฟราเรด เพื่อนำมาสร้างวิธีทำนายพื้นที่ที่คาดว่าฝนจะตกหนัก และวิธีวัดผลการทำนายสภาพอากาศจากหลักสถิติเพื่อนำไปปรับใช้สำหรับการเพิ่มความแม่นยำของโมเดล รวมไปถึงเครื่องมือสำหรับพัฒนาเว็บแอปพลิเคชัน ซึ่งผู้จัดทำได้เรียนรู้เกี่ยวกับการออกแบบทั้งหน้าเว็บและส่วนหลังเว็บ

อย่างไรก็ตาม ในการดำเนินงานที่ผ่านมา คณะผู้จัดทำได้ได้พบอุปสรรคและข้อจำกัดต่าง ๆ ของโครงการได้ ดังต่อไปนี้ ระบบต้องใช้พลังในการประมวลผลสูงแต่มีทรัพยากรจำกัด เนื่องจาก ข้อมูลขาเข้า และข้อมูลขาออก เป็น ลำดับข้อมูล(ลำดับ) ของภาพที่มีขนาด  $600 \times 500$  ต่อกันหลายๆ ภาพ ทำให้การที่จะประมวลผล โครงข่ายประสาทเทียม นั้นต้องใช้เวลา และทรัพยากรสูง อีกทั้งพลังการประมวลผลที่คณะผู้พัฒนามีในตอนนั้นไม่สามารถที่จะประมวลผลภาพที่เป็น RGB ได้ ถ้ามีความสามารถในการประมวลผลที่สูงเพียงพอ จะสามารถคำนวณรูปภาพที่มีหลายย่านความถี่อินฟราเรดรวมกันได้ ซึ่งจะมีตัวแปรที่เกี่ยวข้องมากขึ้นสำหรับการคำนวณ แต่จะทำนายสภาพอากาศที่หลากหลายได้ หรือหาก

สามารถลดมิติของข้อมูลลงได้โดยไม่สูญเสียตัวแปรที่สำคัญออกไป จะทำให้สามารถคำนวณได้รวดเร็วขึ้น และลดการใช้ทรัพยากรในการคำนวณน้อยลง

ปัญหาของ ชุดข้อมูล นั้นมีตั้งแต่ปริมาณของข้อมูลที่ไม่เพียงพอ ลักษณะของภาพถ่ายดาวเทียมไม่เป็นไปตามที่ต้องการ และความเร็วของการดึงข้อมูล ชุดข้อมูล แบบ เวลาจริง (real time) เรื่องจำนวน ชุดข้อมูล ที่มีน้อยทำให้ความแม่นยำของโมเดลลดลง อีกทั้งทำให้การทำนายสภาพอากาศเป็นไปได้ยาก เนื่องจากมีข้อมูลที่น้อยเกินไปผู้พัฒนาจึงทำในลักษณะการทำนายการเคลื่อนที่ของเมฆแทน ถ้าเพิ่มจำนวนข้อมูลและทรัพยากรในการคำนวณ จะสามารถเพิ่มความแม่นยำและลดระยะเวลาของการทำนายได้ ในส่วนของการดึงข้อมูลแบบเรียลไทม์นั้นเป็นไปได้ยาก เนื่องจากทางเว็บไซต์กรมอุตุนิยมวิทยาญี่ปุ่น จะทำการปิดการเข้าถึงภาพถ่ายทางอากาศของช่วงเวลาที่ใกล้เคียงปัจจุบันเป็นเวลาประมาณ 10-15 นาที และ เนื่องรูปภาพถ่ายดาวเทียมบางประเภทไม่สามารถทำการ Preprocessing ได้เนื่องจากกลางวันและกลางคืนส่งผลต่อลักษณะรูปภาพ และสีของรูปที่มีสีใกล้เคียงกับเส้นแผนที่ ส่วนทางเว็บไซต์ กรมอุตุนิยมวิทยาญี่ปุ่น มีภาพถ่ายดาวเทียมบางช่วงเวลาที่เสีย ทำให้มี ข้อมูลขาดเข้า ที่บางช่วงเวลานั้นหายไป และต้องทดแทนด้วย ข้อมูลขาดเข้า ตัวก่อนหน้า รวมถึงทาง กรมอุตุนิยมวิทยาญี่ปุ่น ไม่ได้ให้รูปภาพของย่านอินฟราเรด ทุกแบบ ทำให้ไม่สามารถสังเกตสภาพอากาศอื่นนอกเหนือจากฝนได้นอกจากนั้นภาพที่โมเดลทำนายออกมานั้นมี คุณลักษณะของภาพที่แตกต่างกับภาพอินฟราเรดที่เกิดขึ้นจริงทำให้การสร้าง พื้นที่ที่มีโอกาสฝนตกหนัก นั้นคลาดเคลื่อนจากของจริงไปอีกข้อมูลภาพถ่ายดาวเทียมที่ได้มามีเส้นแผนที่ปนอยู่ ต้องทำการ preprocessing ก่อนนำมาใช้สร้างโมเดล อย่างไรก็ตาม ยังมีสัญญาณรบกวนเหลืออยู่ ซึ่งส่งผลกระทบต่อภาพที่ถูกโมเดลทำนายออกมา ทางกรมอุตุนิยมวิทยาญี่ปุ่น นั้นให้มาเพียงแค่ภาพในย่านอินฟราเรดเพียงไม่กี่ช่วงความถี่ทำให้ประสิทธิภาพของ ฟังก์ชันการทำนายพื้นที่ฝนตกหนัก ที่ทางผู้จัดทำสร้างขึ้นมานั้นลดลง และหากต้องการแก้ไขปัญหากับชุดข้อมูล ที่กล่าวมานี้ ในครั้งถัดไปหากสามารถประสานงานกับทาง กรมอุตุนิยมวิทยาญี่ปุ่น ได้ จะมีโอกาสที่ผู้จัดทำจะสามารถได้รับ ชุดข้อมูล ในแบบที่ต้องการได้

## เอกสารอ้างอิง

1. Seungkyun Hong, Seongchan Kim, Minsu Joh, Sa-kwang Song, “Next ลำดับ การทำนาย of Satelllite Images using a Convolutional ลำดับ-to-ลำดับ Network, ” Korea University of Science and Technology, Korea Institute of Science and Technology Information, DLPS 2017
2. Japan Meteorological Agency. 2017. Meteorological Satellite Center (MSC) of JMA. [ออนไลน์] เข้าถึงได้จาก : <http://www.jma-net.go.jp/msc/en/>. [28 กันยายน 2561]
3. นางสาวธัญปวีณ์ ชัยธัญวิวัฒน์. 2016,อุบัติเหตุเครื่องบินกับธุรกิจการบิน, คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์
4. Stanislav Szabo, eter Vittek, Jakub Kraus, Iveta Vajdová, “Probabilistic model for airport runway safety areas,” Technical University of Kosice, Czech Technical University in Prague, Transport Problems 12(2):89-97 · June 2017
5. Recurrent\_neural\_network [ออนไลน์], เข้าถึงได้จาก : [https://en.wikipedia.org/wiki/Recurrent\\_neural\\_network](https://en.wikipedia.org/wiki/Recurrent_neural_network) [28 กันยายน 2561]
6. Long\_short-term\_memory [ออนไลน์]ม เข้าถึงได้จาก :[https://en.wikipedia.org/wiki/Long\\_short-term\\_memory](https://en.wikipedia.org/wiki/Long_short-term_memory) [ 28 กันยายน 2561]
7. Zihao.chen. (2017).RNN\_Pytorch. Retrived, [ออนไลน์] เข้าถึงได้จาก: [https://github.com/chencodeX/RNN\\_Pytorch](https://github.com/chencodeX/RNN_Pytorch) [25 ตุลาคม 2561]
8. ชูพันธุ์ ชมภูจันทร์ , เขตภูมิอากาศของโลก [ออนไลน์]: เข้าถึงได้จาก [https://www.baanjomyut.com/library/global\\_community/01\\_3.html](https://www.baanjomyut.com/library/global_community/01_3.html), [29 กันยายน 2561]
9. กรมอุตุนิยมวิทยา, หนังสืออุตุนิยมวิทยา [ออนไลน์], เข้าถึงได้จาก: <https://www.tmd.go.th/info/info.php?FileID=55> , [29 กันยายน 2561]
10. Mashable, Flight delays are costing airlines serious money [ออนไลน์], เข้าถึงได้จาก: <https://mashable.com/2014/12/10/cost-of-delayed-flights/#YNvUEWSVhsq5>, [30 กันยายน 2561]
11. Howstuffworks, How much fuel does an international plane use for a trip? [ออนไลน์], เข้าถึงได้จาก: <https://science.howstuffworks.com/transport/flight/modern/question192.html> [ 1 ตุลาคม 2561]

12. โอกาสเกิดฝนตกหนัก Function and it's performance [ออนไลน์], เข้าถึงได้จาก:  
[http://www.data.jma.go.jp/mscweb/data/himawari/Users\\_Guide.pdf](http://www.data.jma.go.jp/mscweb/data/himawari/Users_Guide.pdf) [20 กุมภาพันธ์ 2562]
13. Properties of each Infrared band and RGB composite [ออนไลน์], เข้าถึงได้จาก:  
[http://www.data.jma.go.jp/mscweb/en/VRL/VLab\\_RGB/materials/Outline\\_RGB\\_composite.pdf](http://www.data.jma.go.jp/mscweb/en/VRL/VLab_RGB/materials/Outline_RGB_composite.pdf) [20 กุมภาพันธ์ 2562]
14. Xingjian Shi, Zhihan Gao, Leonard Lausen, Hao Wang, "Deep Learning for Precipitation Nowcasting: A Benchmark and A New Model, " Department of Computer Science and Engineering, Hong Kong University of Science and Technology DLPS 2017
15. forecast verification [ออนไลน์], เข้าถึงได้จาก:  
<http://www.cawcr.gov.au/projects/verification/> [20 กุมภาพันธ์ 2562]